



清华大学

综合论文训练

基于协同引导的多模态生成式推荐方法研究

系 别： 软件学院

专 业： 软件工程

姓 名： 张 镕 州

指导教师： 张 慧 副研究员

二〇二六年五月

关于论文使用授权的说明

本人完全了解清华大学有关保留、使用综合论文训练论文的规定，即：学校有权保留论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

作者签名：

导师签名：

日 期：

日 期：

摘 要

生成式推荐是一种将推荐问题转化为序列生成任务的新范式，其核心在于为每个物品构建高质量的语义标识符。现有的语义标识符构建方法，有的仅利用文本语义信息进行向量量化，有的虽然通过辅助对比损失引入了协同过滤信号，但其融合方式较为间接，且均未考虑视觉模态的信息。针对上述不足，本文提出了 COMET (Collaborative-guided Multimodal Encoding Tokenizer)，一种基于协同过滤引导的多模态语义标识符构建方法。COMET 的核心是一个以协同过滤为查询的交叉注意力融合模块：以协同过滤嵌入作为查询向量，以文本多 token 投影和图像嵌入构成的键值序列为键值对，通过堆叠的交叉注意力和前馈网络自适应地从文本和视觉特征中提取对推荐有用的信息。同时，COMET 采用多目标重建策略，以加权方式同时重建文本、图像和协同过滤嵌入，促进多模态信息在隐空间中的均衡编码。在 Amazon Beauty 数据集上的实验表明，本文提出的方法构建的语义标识符在两种主流生成式推荐模型上均取得了较好的推荐性能。

关键词：生成式推荐；语义 ID；多模态融合；协同过滤；残差向量量化

Abstract

Generative recommendation is an emerging paradigm that formulates the recommendation task as a sequence generation problem, where the quality of item semantic identifiers plays a critical role. Existing semantic identifier construction methods have limitations: some rely solely on textual semantics for vector quantization, while others introduce collaborative filtering signals through an auxiliary contrastive loss in an indirect manner, and neither incorporates visual modality information. To address these limitations, this thesis proposes COMET (Collaborative-guided Multimodal Encoding Tokenizer), a multimodal semantic identifier construction method guided by collaborative filtering. The core of COMET is a cross-attention fusion module with collaborative filtering as query: it uses collaborative filtering embeddings as queries and a key-value sequence composed of multi-token text projections and image embeddings, adaptively extracting recommendation-relevant information from textual and visual features through stacked cross-attention and feed-forward layers. Furthermore, COMET adopts a multi-target reconstruction strategy that simultaneously reconstructs text, image, and collaborative filtering embeddings with weighted losses, promoting balanced multimodal encoding in the latent space. Experiments on the Amazon Beauty dataset demonstrate that the proposed method achieves favorable recommendation performance on two mainstream generative recommendation models.

Keywords: Generative Recommendation; Semantic ID; Multimodal Fusion; Collaborative Filtering; Residual Vector Quantization

目 录

第 1 章 绪 论.....	1
1.1 研究背景与意义	1
1.2 研究内容与创新点	2
1.3 论文组织结构	2
第 2 章 相关工作.....	4
2.1 序列推荐	4
2.2 生成式推荐	4
2.3 语义 ID 构建方法.....	5
2.3.1 RQ-VAE	5
2.3.2 RQ-KMeans.....	6
2.3.3 LETTER.....	7
2.4 多模态推荐	8
第 3 章 基于协同引导的多模态语义 ID 构建方法	10
3.1 问题定义	10
3.2 整体框架	10
3.3 多模态嵌入提取	11
3.3.1 文本嵌入	11
3.3.2 图像嵌入	12
3.3.3 协同过滤嵌入	12
3.4 基于协同引导的多模态融合模块	12
3.4.1 特征对齐投影器	12
3.4.2 协同引导交叉注意力网络	13
3.4.3 码本特征映射器	13
3.5 残差向量量化	14
3.6 损失函数设计	14
3.7 Sinkhorn 碰撞优化	15
3.8 本章小结	15
第 4 章 实 验.....	16
4.1 实验设置	16
4.1.1 数据集.....	16

4.1.2 评价指标	16
4.1.3 基线方法	18
4.1.4 下游推荐模型	18
4.1.5 实现细节	19
4.2 主实验结果	19
4.3 消融实验	21
4.4 长尾物品推荐分析	23
4.5 语义 ID 质量分析	24
4.6 本章小结	27
第 5 章 总结与展望	28
5.1 工作总结	28
5.2 未来展望	28
参考文献	29
致 谢	31
声 明	32

插图清单

图 2.1 RQ-VAE 架构示意图 ^[5]	5
图 2.2 RQ-KMeans 架构示意图 ^[12]	7
图 2.3 LETTER 架构示意图 ^[6]	7
图 3.1 COMET 整体框架	11
图 4.1 COMET 与 RQ-VAE 的推荐对比实例 1.....	21
图 4.2 COMET 与 RQ-VAE 的推荐对比实例 2.....	22
图 4.3 长尾物品分布.....	24
图 4.4 冲突率案例分析: 同系列不同色号唇膏的语义 ID 对比	26

附表清单

表 4.1 Amazon Beauty 数据集统计	16
表 4.2 COMET 超参数设置	17
表 4.3 TIGER 结合不同语义 ID 方法的推荐性能	19
表 4.4 OneRec 结合不同语义 ID 方法的推荐性能	20
表 4.5 COMET 关键组件的消融实验结果 (OneRec)	22
表 4.6 热门物品与长尾物品推荐性能对比 (OneRec)	23
表 4.7 不同语义 ID 方法的碰撞对比	25

第 1 章 绪 论

1.1 研究背景与意义

推荐系统是现代互联网平台的核心技术之一，旨在从海量候选物品中为用户筛选出可能感兴趣的内容。随着电子商务、社交媒体和内容平台的快速发展，推荐系统在提升用户体验和商业价值方面发挥着日益重要的作用。

序列推荐 (Sequential Recommendation) 是推荐系统领域的重要研究方向，其核心思想是根据用户的历史交互序列预测其下一个可能交互的物品。传统的序列推荐方法，如基于循环神经网络的 GRU4Rec^[1] 和基于自注意力机制的 SASRec^[2]，通过学习物品 ID 的嵌入表示来建模用户偏好的动态变化。然而，这类方法依赖于独立的物品 ID 嵌入，无法建模物品之间的语义关联，且对新物品的泛化能力有限。

近年来，生成式推荐 (Generative Recommendation) 作为一种新范式受到了广泛关注^[3-4]。其核心思想是：首先为每个物品分配一个由多层离散编码组成的语义 ID (Semantic ID)，然后将推荐问题转化为序列到序列的生成任务——给定用户历史交互物品的语义 ID 序列，自回归地生成下一个物品的语义 ID。与传统方法相比，生成式推荐具有以下优势：(1) 语义 ID 编码了物品的内容特征，语义相似的物品拥有相近的编码，有助于知识迁移；(2) 生成式框架天然支持开放词汇，对新物品具有更好的泛化性；(3) 多层级的编码结构实现了从粗到细的物品检索。

在生成式推荐框架中，语义 ID 的构建质量直接决定了推荐性能的上限。目前主流的语义 ID 构建方法基于残差量化变分自编码器 (RQ-VAE)^[3,5]，将物品的文本嵌入通过编码器映射到低维隐空间，再经过多层残差向量量化生成离散编码。然而，现有方法在模态利用和信号融合方面存在明显不足：

第一，**模态利用单一**。主流方法仅利用文本语义信息构建语义 ID。以 TIGER^[3] 为代表的方法使用预训练语言模型提取物品文本嵌入，然后直接进行向量量化。然而，在电商等场景中，物品的视觉外观往往是影响用户决策的关键因素，忽视图像信息会导致语义 ID 无法全面描述物品特征。

第二，**协同过滤信号融合不够直接**。LETTER^[6] 率先尝试在语义 ID 构建中引入协同过滤 (Collaborative Filtering, CF) 信号，通过在 RQ-VAE 的训练损失中添加 InfoNCE 对比损失来对齐量化后的隐向量与 CF 嵌入。这种通过辅助损失间接融合的方式需要额外引入对比损失函数并仔细调节其权重，融合程度难以控制等问题。

第三，**缺乏有效的多模态融合机制**。现有的语义 ID 构建工作尚未探索如何将文本、图像和协同过滤三种异构模态有效融合到统一的语义 ID 表示中。简单的特

征拼接或加权平均无法捕捉模态间的复杂交互关系。

1.2 研究内容与创新点

针对上述问题,本文提出了 COMET (Collaborative-guided Multimodal Encoding Tokenizer),一种基于协同过滤引导的多模态语义 ID 构建方法,并搭建了完整的实验验证框架。本文的主要研究内容和创新点包括:

(1) **提出了协同引导交叉注意力融合机制。**COMET 将协同过滤嵌入作为注意力查询 (Query),将文本多 token 投影和图像嵌入构成的键值序列作为键值对 (Key-Value),通过多层堆叠的交叉注意力和前馈网络实现三模态深度融合。文本嵌入被分割为 4 个子空间分别投影,形成 4 个 KV token,使注意力能够细粒度地选择文本信息。这一设计的直觉在于:协同过滤信号反映了用户群体的行为偏好,用其作为查询可以自适应地从文本和视觉特征中提取对推荐最有价值的信息。与 LETTER 的辅助损失方式相比,COMET 将协同过滤信号通过模型架构直接融入编码过程,无需引入额外的对比损失函数及其权重调节。

(2) **提出多目标重建策略促进多模态信息均衡编码。**COMET 采用三个独立的解码器分支,以加权方式同时重建文本、图像和协同过滤三种模态的嵌入。文本嵌入作为维度最高、信息量最丰富的模态赋予最大权重,图像和协同过滤嵌入的重建起正则化作用,迫使隐向量在编码文本语义的同时保留视觉和协同过滤信号,实现多模态信息在隐空间中的均衡编码。

(3) **构建了完整的多模态生成式推荐实验框架。**本文搭建了从原始数据处理、多模态嵌入提取、语义 ID 构建到生成式推荐模型训练和评估的完整实验流水线,实现了 RQ-KMeans、RQ-VAE、LETTER 和 COMET 四种语义 ID 构建方法的公平对比,并在 TIGER 和 OneRec 两种代表性生成式推荐模型上验证了 COMET 的有效性。

1.3 论文组织结构

本文的组织结构如下:

第 1 章为绪论,介绍研究背景、问题提出和主要创新点。

第 2 章为相关工作,综述序列推荐、生成式推荐、语义 ID 构建和多模态推荐的相关研究。

第 3 章为方法,详细描述 COMET 的整体框架,包括多模态嵌入提取、基于协同引导的多模态融合模块、残差向量量化、损失函数设计以及 Sinkhorn 碰撞优化

策略。

第 4 章为实验，在 Amazon Beauty 数据集上全面的实验评估，包括主实验、消融实验、长尾物品推荐分析和语义 ID 质量分析。

第 5 章为总结与展望，总结本文的工作并讨论未来的研究方向。

第 2 章 相关工作

本章对与本文研究相关的工作进行综述，主要包括序列推荐、生成式推荐、语义 ID 构建方法和多模态推荐四个方面。

2.1 序列推荐

序列推荐旨在根据用户的历史交互序列建模其动态偏好，预测下一个可能交互的物品。早期的序列推荐方法基于马尔可夫链，假设下一个交互仅依赖于最近的少量交互^[7]。随着深度学习的发展，基于神经网络的序列推荐方法取得了显著进展。

GRU4Rec^[1]首次将门控循环单元（GRU）引入基于会话的推荐，通过循环神经网络建模交互序列的时序依赖关系。Caser^[8]则从另一个角度出发，将用户的近期交互嵌入矩阵视为“图像”，利用卷积神经网络捕捉序列中的局部模式。

SASRec^[2]是序列推荐领域的里程碑工作，它将自注意力机制引入序列推荐，通过单向 Transformer 编码器对用户历史交互序列进行建模。SASRec 使用因果注意力掩码确保每个位置只关注之前的交互，有效捕捉了长距离依赖关系。在此基础上，BERT4Rec^[9]借鉴 BERT 的掩码语言模型思想，采用双向自注意力和完形填空训练策略，在部分场景下取得了进一步提升。

值得注意的是，上述方法均基于独立的物品 ID 进行嵌入学习，物品之间的语义关联完全依赖于协同过滤信号通过训练隐式习得。这种方式在冷启动场景下表现不佳，且无法利用物品的内容信息。本文使用 SASRec 作为协同过滤嵌入的提取器，其学习到的物品嵌入编码了用户行为模式中的协同信号，为 COMET 融合模块提供了重要的输入。

2.2 生成式推荐

生成式推荐将推荐问题重新表述为序列生成任务。其核心思想是：首先为每个物品分配一个由多层离散编码组成的语义 ID，然后训练生成模型根据用户历史交互物品的语义 ID 序列，自回归地生成下一个物品的语义 ID。

TIGER^[3]是生成式推荐的代表性工作。它使用 RQ-VAE 将物品的文本嵌入量化为多层语义 ID，然后基于 T5^[10]编码器-解码器架构，将用户历史中所有物品的语义 ID 拼接为输入序列，自回归地生成目标物品的 4 层语义 ID。TIGER 还提出

了基于前缀树（Trie）的约束束搜索，确保生成的语义 ID 序列一定对应某个真实物品，有效避免了无效生成。

P5^[11]从另一个角度探索生成式推荐，将多种推荐任务（评分预测、序列推荐、解释生成等）统一为自然语言生成任务，使用单一的 T5 模型处理。LC-Rec^[4]提出了对齐-生成两阶段训练范式，通过协同语义对齐提升大语言模型在推荐任务上的表现。LETTER^[6]则专注于可学习的物品标记化方法，通过引入协同过滤信号改进语义 ID 的构建质量。

OneRec^[12]是另一种代表性的生成式推荐模型，采用了不同于 T5 的自定义 Transformer 架构。OneRec 使用交叉注意力机制将用户历史编码为键值（Key-Value）缓存，解码器通过交叉注意力查询历史上下文并自回归生成目标语义 ID。其架构借鉴了大语言模型的设计，使用 RMSNorm^[13]、SiLU 门控前馈网络^[14]和更大的模型容量（1024 维、12 层）。

生成式推荐的性能很大程度上取决于语义 ID 的质量。如果语义 ID 不能有效编码物品特征，生成模型即使结构再先进也难以学习到有效的推荐模式。因此，本文聚焦于语义 ID 构建方法的改进。

2.3 语义 ID 构建方法

语义 ID 构建的目标是为每个物品分配一个由多层离散编码组成的标识符，使得语义相似的物品具有相近的编码。目前主流的方法基于残差量化（Residual Quantization）。

2.3.1 RQ-VAE

残差量化变分自编码器（RQ-VAE）^[5]是语义 ID 构建的基础框架。其结构包含编码器、残差向量量化器和解码器三部分。




图 2.1 RQ-VAE 架构示意图^[5]

编码器将物品的高维嵌入（如 4096 维的文本嵌入）通过多层感知机映射到低维隐向量 $\mathbf{z} \in \mathbb{R}^d$ （如 $d = 32$ ）。残差向量量化器包含 L 层，每层维护一个码本 $\mathbf{C}^{(l)} = \{\mathbf{c}_1^{(l)}, \dots, \mathbf{c}_K^{(l)}\} \subset \mathbb{R}^d$ （ K 通常为 256）。量化过程按层级进行：

$$\mathbf{r}^{(0)} = \mathbf{z}, \quad (2.1)$$

$$k^{(l)} = \arg \min_k \|\mathbf{r}^{(l-1)} - \mathbf{c}_k^{(l)}\|^2, \quad l = 1, \dots, L, \quad (2.2)$$

$$\mathbf{r}^{(l)} = \mathbf{r}^{(l-1)} - \mathbf{c}_{k^{(l)}}^{(l)}, \quad (2.3)$$

其中 $\mathbf{r}^{(l)}$ 为第 l 层的残差， $k^{(l)}$ 为第 l 层分配的编码索引。物品的语义 ID 即为 $(k^{(1)}, k^{(2)}, \dots, k^{(L)})$ 。

解码器将量化后的表示 $\hat{\mathbf{z}} = \sum_{l=1}^L \mathbf{c}_{k^{(l)}}^{(l)}$ 重建为原始嵌入。训练损失为重建损失与承诺损失之和：

$$\mathcal{L}_{\text{RQ-VAE}} = \|\mathbf{x}_{\text{rec}} - \mathbf{x}\|^2 + \beta \sum_{l=1}^L \|\mathbf{r}^{(l-1)} - \text{sg}[\mathbf{c}_{k^{(l)}}^{(l)}]\|^2, \quad (2.4)$$

其中 $\text{sg}[\cdot]$ 表示停止梯度操作， β 为承诺损失权重。码本通过指数移动平均（EMA）更新，并配合死码重启机制维持码本利用率。

RQ-VAE 通过端到端训练优化编码质量，相比简单的聚类方法能够学习到更适合重建任务的表示。然而，RQ-VAE 仅利用文本模态信息，且训练目标仅为重建文本嵌入，未考虑推荐任务中的协同过滤信号和其他模态信息，这限制了其构建的语义 ID 在推荐场景下的表现。

2.3.2 RQ-KMeans

RQ-KMeans^[12] 是一种更简单直接的语义 ID 构建方法，它直接在原始嵌入空间上进行残差聚类，无需训练编码器和解码器。

具体而言，RQ-KMeans 使用 faiss 库的 KMeans 算法对物品嵌入进行多层残差聚类。第一层对所有物品的原始嵌入 $\mathbf{x} \in \mathbb{R}^D$ （如 4096 维文本嵌入）进行 KMeans 聚类，得到 K 个聚类中心，每个物品被分配到最近的聚类中心，该聚类索引即为第一层编码 $k^{(1)}$ 。随后计算残差 $\mathbf{r}^{(1)} = \mathbf{x} - \mathbf{c}_{k^{(1)}}^{(1)}$ ，在残差空间上继续进行 KMeans 聚类得到第二层编码，如此迭代 L 层。

RQ-KMeans 的优势在于方法简单、无需训练、稳定性高，但其局限性也很明显：（1）直接在高维原始空间聚类，无法通过学习优化编码质量；（2）无法引入协同过滤等额外监督信号；（3）聚类过程完全基于欧氏距离，可能无法捕捉语义相似性。尽管如此，RQ-KMeans 在实践中仍能取得有竞争力的结果，常被用作基线方法。




图 2.2 RQ-KMeans 架构示意图^[12]

2.3.3 LETTER

LETTER^[6]在 RQ-VAE 的基础上做了两项重要改进：




图 2.3 LETTER 架构示意图^[6]

第一，引入协同过滤对比损失。LETTER 使用预训练的 SASRec 模型提取物品的协同过滤嵌入 $\mathbf{e}_{cf}$ ，然后在训练损失中添加 InfoNCE 对比损失：

$$\mathcal{L}_{cf} = -\log \frac{\exp(\text{sim}(\hat{\mathbf{z}}, \mathbf{e}_{cf})/\tau)}{\sum_{j=1}^B \exp(\text{sim}(\hat{\mathbf{z}}, \mathbf{e}_{cf,j})/\tau)}, \quad (2.5)$$

其中 $\text{sim}(\cdot, \cdot)$ 为余弦相似度， $\tau = 0.07$ 为温度参数， B 为批大小。这一损失要求量化后的语义表示与对应的协同过滤嵌入在表示空间中对齐。为避免对比损失干扰

编码器和码本的初始化，LETTER 采用了预热-渐变调度：前 50 个训练周期不使用协同过滤对比损失，之后在 50 个周期内线性增加其权重至目标值。

第二，**码本多样性损失**。LETTER 对每层码本的码向量进行 KMeans 聚类，然后在同一聚类内的码向量之间施加对比学习损失，鼓励聚类内部的码向量保持可区分性，促进码本的充分利用。

LETTER 的总损失为：

$$\mathcal{L}_{\text{LETTER}} = \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{vq}} + \alpha \mathcal{L}_{\text{cf}} + \gamma \mathcal{L}_{\text{div}}, \quad (2.6)$$

其中 α 为协同过滤对比损失权重（经调度后为 0.05）， γ 为多样性损失权重（0.0001）。

LETTER 的局限性在于：协同过滤信号仅通过辅助损失间接影响编码过程，需要额外引入对比损失函数并仔细调节其权重；同时仍仅使用文本模态作为编码器输入，未利用图像信息。

2.4 多模态推荐

多模态信息在推荐系统中的应用日益受到关注。近年来，随着预训练多模态模型（如 CLIP^[15]）的发展，研究者开始探索如何有效融合文本、图像等多种模态信息以提升推荐性能。

MQL4GRec^[16] 提出了多模态量化语言的概念，旨在将不同模态的物品内容转化为统一的离散编码序列，从而实现跨域推荐中的知识迁移。该方法的核心是量化翻译器，由模态编码器和向量量化器组成。对于文本模态，MQL4GRec 使用预训练语言模型提取文本嵌入，然后通过残差量化变分自编码器将其映射为离散的 token 序列；对于图像模态，使用预训练的视觉编码器提取图像特征，同样经过残差量化变分自编码器生成离散编码。这样，不同模态的物品内容都被转化为统一的量化语言表示。为了促进模态间的知识交互，MQL4GRec 设计了量化语言对齐任务，通过对比学习显式地对齐文本和图像的量化表示，使得语义相似的文本和图像在量化语言空间中具有相近的编码。此外，该方法还设计了下一物品生成和非对称物品生成等自监督任务，使量化语言能够编码推荐相关的语义信息和先验知识。实验表明，MQL4GRec 在跨域推荐任务中取得了显著的性能提升，验证了统一量化语言表示的有效性。

与 MQL4GRec 类似，Q-Bert4Rec^[17] 也将语义 ID 的思想引入多模态序列推荐。该方法首先使用预训练的文本编码器和图像编码器分别提取物品的文本嵌入和图像嵌入，然后将两种模态的嵌入进行加权融合，得到统一的多模态表示。接着，通过残差向量量化将融合后的连续嵌入映射为多层离散编码，每一层量化都在前一

层的残差上进行，最终形成多层语义 ID。在序列推荐阶段，采用双向 Transformer 架构，将用户历史交互物品的语义 ID 序列作为输入，通过掩码语言模型的方式预测被掩码位置的物品语义 ID。实验表明，该方法在多个数据集上取得了较好的推荐性能。

上述工作表明，多模态信息的融合能够有效提升推荐性能。然而，这些方法主要关注如何在推荐模型层面融合多模态特征，或是将不同模态分别量化后进行对齐。本文则从不同的角度出发，在语义 ID 的编码阶段就将文本、图像和协同过滤信号通过交叉注意力机制深度融合，使生成的语义 ID 能够同时编码多种模态的信息，从而为下游生成式推荐模型提供更高质量的物品表示。

第 3 章 基于协同引导的多模态语义 ID 构建方法

本章详细介绍本文提出的 COMET (Collaborative-guided Multimodal Encoding Tokenizer) 方法。首先给出问题定义，然后描述整体框架，接着分别介绍多模态嵌入提取、多模态融合模块、残差向量量化、损失函数设计以及 Sinkhorn 碰撞优化策略。

3.1 问题定义

设物品集合为 $\mathcal{I} = \{i_1, i_2, \dots, i_N\}$ ，用户集合为 $\mathcal{U} = \{u_1, u_2, \dots, u_M\}$ 。每个用户 u 有一个按时间排序的交互序列 $\mathcal{S}_u = [s_1, s_2, \dots, s_T]$ ，其中 $s_t \in \mathcal{I}$ 。序列推荐的目标是根据 $\mathcal{S}_u$ 预测用户下一个将要交互的物品 s_{T+1} 。

在生成式推荐框架中，每个物品被映射为一个多层离散编码的语义 ID：

$$\text{SID}(i) = (c_1, c_2, \dots, c_L), \quad c_l \in \{0, 1, \dots, K-1\}, \quad (3.1)$$

其中 L 为码本层数， K 为每层的码本大小。在本文的实验设置中， $L = 4$ ， $K = 256$ 。语义 ID 的构建应满足以下性质：(1) 语义相似的物品具有相近的编码，(2) 不同物品尽量具有不同的编码，(3) 编码层级从粗到细，第一层捕捉物品的大类别，后续层逐步细化。

生成式推荐将序列推荐重新表述为序列到序列的生成任务。给定用户交互历史 $\mathcal{S}_u = [s_1, \dots, s_T]$ ，将每个物品替换为其语义 ID，得到输入序列：

$$\mathbf{X} = [\text{SID}(s_1); \text{SID}(s_2); \dots; \text{SID}(s_T)]. \quad (3.2)$$

生成模型以 $\mathbf{X}$ 为输入，自回归地生成目标物品 s_{T+1} 的语义 ID。由于语义 ID 由 L 层编码组成，生成过程可以分解为逐层预测，即预测下一个物品的概率可以表示为：

$$P(s_{T+1} | \mathcal{S}_u) = \prod_{l=1}^L P(c_l | \mathbf{X}, c_1, \dots, c_{l-1}). \quad (3.3)$$

3.2 整体框架

COMET 的整体框架如图 3.1 所示，主要包括以下几个部分：

1. **多模态嵌入提取**：分别使用 Qwen3-Embedding-8B、CLIP ViT-L/14 和 SASRec 提取物品的文本嵌入（4096 维）、图像嵌入（768 维）和协同过滤嵌入（128

- 维)。
2. **多模态融合模块**：通过协同引导交叉注意力机制将三种模态嵌入融合为 64 维隐向量。
 3. **残差向量量化**：将隐向量通过 4 层残差量化生成离散的 4 层语义 ID。
 4. **下游生成推荐**：将构建的语义 ID 输入 TIGER 或 OneRec 进行生成式推荐。




图 3.1 COMET 整体框架

3.3 多模态嵌入提取

COMET 的输入由三种模态的物品嵌入组成，分别编码了物品的文本语义、视觉外观和协同过滤信号。

3.3.1 文本嵌入

文本嵌入是语义 ID 的核心信息来源。本文为每个物品构建结构化的文本描述，包含标题、品牌、价格、商品描述和类别信息，格式如下：

Title: <标题>

Brand: <品牌>

Price: \$<价格>

Description: <商品描述>

Categories: <类别1> > <类别2> > <类别3>

使用 Qwen3-Embedding-8B^[18] 作为文本编码器。该模型是一个 80 亿参数的文本嵌入模型，通过 last-token 池化提取 4096 维的密集表示。在推理时，为输入文本添加指令前缀 “Represent the item description for recommendation:” 以引导模型关注

推荐相关的语义信息。

3.3.2 图像嵌入

图像嵌入补充了物品的视觉外观信息。在电商场景中，商品图片直观展示了颜色、形状、材质等文本难以精确描述的属性，对用户的购买决策具有重要影响。

本文使用 CLIP ViT-L/14^[15] 作为图像编码器。CLIP 通过在 4 亿图文对上进行对比学习，其视觉编码器能够提取具有语义理解能力的 768 维图像表示。对于少量缺失图像的物品（Amazon Beauty 数据集中约 8 个物品），使用零向量作为占位，并在多模态融合模块中通过可学习填充向量处理。

3.3.3 协同过滤嵌入

协同过滤嵌入编码了物品在用户行为空间中的表示，反映了购买了 A 的用户也倾向于购买 B 这类协同信号。

本文使用预训练的 SASRec^[2] 模型提取协同过滤嵌入。SASRec 在用户交互序列上通过交叉熵损失训练，其物品嵌入表 $\mathbf{E} \in \mathbb{R}^{N \times d_{cf}}$ 中的每一行编码了对应物品的协同过滤信息。本文使用的 SASRec 模型的隐藏维度 $d_{cf} = 128$ 。

3.4 基于协同引导的多模态融合模块

COMET 的核心创新是协同引导交叉注意力融合模块，用于将三种模态的嵌入融合为统一的低维表示。

3.4.1 特征对齐投影器

首先，将三种不同维度的模态嵌入投影到统一的注意力操作维度 d_{model} （本文设为 256）。

文本多 token 投影。原始文本嵌入 $\mathbf{e}_{text} \in \mathbb{R}^{4096}$ 维度远高于其他模态，单一线性投影会导致严重的信息压缩损失。为此，COMET 将 4096 维文本嵌入均匀分割为 4 个 1024 维的片段，每个片段使用独立的线性投影映射到 d_{model} 维：

$$\mathbf{e}_{text} = [\mathbf{e}_{text}^{(1)}; \mathbf{e}_{text}^{(2)}; \mathbf{e}_{text}^{(3)}; \mathbf{e}_{text}^{(4)}], \quad \mathbf{e}_{text}^{(j)} \in \mathbb{R}^{1024}, \quad (3.4)$$

$$\mathbf{h}_{text}^{(j)} = \mathbf{W}_{text}^{(j)} \mathbf{e}_{text}^{(j)} + \mathbf{b}_{text}^{(j)}, \quad \mathbf{W}_{text}^{(j)} \in \mathbb{R}^{d_{model} \times 1024}, \quad j = 1, 2, 3, 4. \quad (3.5)$$

这一设计将原始的 1 个文本 KV token 扩展为 4 个 token，每个 token 聚焦于文本嵌入的不同语义子空间，使交叉注意力能够更细粒度地选择文本信息。

图像嵌入和协同过滤嵌入的投影方式不变：

$$\mathbf{h}_{\text{image}} = \mathbf{W}_{\text{image}} \mathbf{e}_{\text{image}} + \mathbf{b}_{\text{image}}, \quad \mathbf{W}_{\text{image}} \in \mathbb{R}^{d_{\text{model}} \times 768}, \quad (3.6)$$

$$\mathbf{h}_{\text{cf}} = \mathbf{W}_{\text{cf}} \mathbf{e}_{\text{cf}} + \mathbf{b}_{\text{cf}}, \quad \mathbf{W}_{\text{cf}} \in \mathbb{R}^{d_{\text{model}} \times 128}. \quad (3.7)$$

对于缺失图像的物品，使用可学习的填充向量 $\mathbf{p} \in \mathbb{R}^{768}$ 替代零向量：

$$\mathbf{e}'_{\text{image}} = \begin{cases} \mathbf{e}_{\text{image}}, & \text{若图像存在,} \\ \mathbf{p}, & \text{否则.} \end{cases} \quad (3.8)$$

3.4.2 协同引导交叉注意力网络

COMET 融合的关键设计是将协同过滤嵌入作为注意力查询，文本和图像嵌入作为键值对，通过多层 Transformer 解码器块实现深度融合。

查询 (Query)：投影后的 CF 嵌入 $\mathbf{Q} = \mathbf{h}_{\text{cf}} \in \mathbb{R}^{1 \times d_{\text{model}}}$ 。

键值对 (Key-Value)：4 个文本 token 和 1 个图像 token 拼接构成 5 个 token 的序列：

$$\mathbf{K} = \mathbf{V} = [\mathbf{h}_{\text{text}}^{(1)}; \mathbf{h}_{\text{text}}^{(2)}; \mathbf{h}_{\text{text}}^{(3)}; \mathbf{h}_{\text{text}}^{(4)}; \mathbf{h}_{\text{image}}] \in \mathbb{R}^{5 \times d_{\text{model}}}. \quad (3.9)$$

多层交叉注意力。COMET 使用 2 层堆叠的 Transformer 解码器块，每层包含交叉注意力和前馈网络 (FFN)。设第 i 层输入为 $\mathbf{q}^{(i)}$ ($\mathbf{q}^{(0)} = \mathbf{Q}$)，每层的计算如下：

$$\mathbf{q}'^{(i)} = \mathbf{q}^{(i)} + \text{CrossAttn}^{(i)}(\text{LN}_1^{(i)}(\mathbf{q}^{(i)}), \text{LN}_2^{(i)}(\mathbf{KV})), \quad (3.10)$$

$$\mathbf{q}^{(i+1)} = \mathbf{q}'^{(i)} + \text{FFN}^{(i)}(\text{LN}_3^{(i)}(\mathbf{q}'^{(i)})), \quad (3.11)$$

其中 LN 为层归一化，FFN 为两层线性变换（维度 $d_{\text{model}} \rightarrow 2d_{\text{model}} \rightarrow d_{\text{model}}$ ）加 GELU 激活。交叉注意力使用 $n_{\text{heads}} = 4$ 个头， $d_{\text{head}} = 64$ 。

与单层注意力相比，2 层堆叠结构使模型具有更强的模态交互建模能力。第一层可以学习初步的模态选择和信息提取，第二层在此基础上进一步精细融合。每层的残差连接保证了 CF 信号的直接传递。

最终融合输出 $\mathbf{f} = \mathbf{q}^{(2)}$ 经过最终的层归一化后输入码本特征映射器。

3.4.3 码本特征映射器

归一化后的特征通过两层感知机映射到码本维度 d_e ：

$$\mathbf{z} = \mathbf{W}_2 \cdot \text{GELU}(\mathbf{W}_1 \mathbf{f} + \mathbf{b}_1) + \mathbf{b}_2, \quad (3.12)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{256 \times 128}$ ， $\mathbf{W}_2 \in \mathbb{R}^{128 \times 64}$ ，最终输出 $\mathbf{z} \in \mathbb{R}^{64}$ 。

3.5 残差向量量化

COMET 采用 4 层残差向量量化将融合后的 64 维隐向量 $\mathbf{z}$ 映射为离散的语义 ID。量化过程与第 2 章介绍的 RQ-VAE 相同：第一层对隐向量进行量化，后续各层对前一层的残差进行量化，最终得到 4 层编码 (c_1, c_2, c_3, c_4)。

由于向量量化操作不可微，训练时采用直通估计器技术：前向传播使用离散的量化向量 $\hat{\mathbf{z}}$ ，反向传播时梯度直接穿过量化操作传递给编码器。这使得编码器能够通过重建损失进行端到端优化。

为保证码本的有效利用，COMET 采用了以下技术：训练开始前使用 KMeans 对各层码本进行初始化；训练过程中码本通过指数移动平均方式更新以保持稳定性，并对长期未被使用的码向量进行重启。

3.6 损失函数设计

COMET 的训练损失由重建损失 $\mathcal{L}_{\text{rec}}$ 和量化损失 $\mathcal{L}_{\text{vq}}$ 组成：

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \lambda \mathcal{L}_{\text{vq}}, \quad (3.13)$$

其中 $\lambda = 1.0$ 为量化损失权重。

重建损失采用多目标重建策略，同时重建文本、图像和协同过滤三种模态的嵌入。COMET 使用三个独立的解码器分支：

- **文本解码器**：5 层 MLP ($64 \rightarrow 256 \rightarrow 512 \rightarrow 1024 \rightarrow 2048 \rightarrow 4096$)，重建原始文本嵌入；
- **图像解码器**：2 层 MLP ($64 \rightarrow 256 \rightarrow 768$)，重建原始图像嵌入；
- **CF 解码器**：2 层 MLP ($64 \rightarrow 128 \rightarrow 128$)，重建原始协同过滤嵌入。

中间层使用 ReLU 激活。设 $\text{Dec}_{\text{text}}(\cdot)$ 、 $\text{Dec}_{\text{image}}(\cdot)$ 和 $\text{Dec}_{\text{cf}}(\cdot)$ 分别表示文本、图像和协同过滤解码器函数。

重建损失为文本、图像和协同过滤三个分支的加权均方误差之和：

$$\mathcal{L}_{\text{rec}} = w_{\text{text}} \|\text{Dec}_{\text{text}}(\hat{\mathbf{z}}) - \mathbf{e}_{\text{text}}\|^2 + w_{\text{image}} \|\text{Dec}_{\text{image}}(\hat{\mathbf{z}}) - \mathbf{e}_{\text{image}}\|^2 + w_{\text{cf}} \|\text{Dec}_{\text{cf}}(\hat{\mathbf{z}}) - \mathbf{e}_{\text{cf}}\|^2, \quad (3.14)$$

其中 $\hat{\mathbf{z}}$ 为经直通估计器处理后的量化表示， $w_{\text{text}} = 1.0$ ， $w_{\text{image}} = 0.1$ ， $w_{\text{cf}} = 0.1$ 。对于缺失图像的物品，图像重建损失项被掩码为零，不参与梯度计算。

多目标重建的设计动机如下：文本嵌入作为维度最高、信息量最丰富的模态，赋予最大的重建权重 (1.0)，确保隐空间以文本语义为主干。图像和 CF 的重建权重较低 (0.1)，起到正则化作用——迫使隐向量 $\mathbf{z}$ 不仅编码文本信息，还需保留一定的视觉和协同过滤信号，从而实现更均衡的多模态融合。相比仅重建文本嵌入，

多目标重建在 64 维隐空间中能更有效地组织多模态信息。

量化损失用于优化残差向量量化过程：

$$\mathcal{L}_{\text{vq}} = \frac{1}{L} \sum_{l=1}^L \|\mathbf{z}_q^{(l)} - \mathbf{z}^{(l)}\|^2, \quad (3.15)$$

其中 $\mathbf{z}^{(l)}$ 为第 l 层的输入向量， $\mathbf{z}_q^{(l)}$ 为量化后的向量。该损失促使输入向量靠近其被分配到的码向量，从而稳定量化过程并提高码本的利用率。

在训练过程中，使用加权重建损失 $\mathcal{L}_{\text{rec}}$ 作为模型选择标准，保存该损失最低的模型检查点。这是因为量化损失的波动较大，直接使用总训练损失可能导致选择到重建质量次优的模型。

3.7 Sinkhorn 碰撞优化

训练完成后，对所有物品进行编码，统计语义 ID 的碰撞情况（多个物品共享相同的语义 ID）。对碰撞组进行迭代优化：

在最后两层量化器上启用 Sinkhorn-Knopp 算法^[19]，将码分配问题转化为最优传输问题。对归一化的距离矩阵 $\mathbf{D}$ 进行迭代行列归一化：

$$\mathbf{Q}^{(0)} = \exp(-\mathbf{D}/\epsilon), \quad \mathbf{Q}^{(t)} = \text{RowNorm}(\text{ColNorm}(\mathbf{Q}^{(t-1)})), \quad (3.16)$$

迭代 50 次后， $\mathbf{Q}$ 趋近于均匀分配矩阵，碰撞组中的物品被分配到不同的码上。

与之前仅在最后一层使用统一温度参数的方案不同，COMET 采用**渐进式温度策略**：第 3 层 $\epsilon_3 = 0.005$ ，第 4 层 $\epsilon_4 = 0.01$ 。较浅层使用较小的 ϵ 以保持编码的精确性，较深层使用较大的 ϵ 以允许更灵活的码分配。在最后两层而非仅最后一层启用 Sinkhorn 优化，能够在更大的编码空间中进行碰撞消解，显著提高碰撞消除的有效性。

3.8 本章小结

本章详细介绍了 COMET 方法的设计细节。COMET 的核心创新在于协同引导交叉注意力融合机制，将协同过滤引导从辅助损失的间接方式提升为架构级别的直接融合，同时引入文本多 token 投影和图像模态信息，构建了 5 个 KV token 的丰富键值序列。在训练策略上，COMET 采用多目标重建损失（文本 + 图像 + CF）促进多模态信息在隐空间中的均衡编码，使用余弦退火学习率调度和训练时 Sinkhorn 均匀化进一步提升码本质量。与 LETTER 相比，COMET 通过架构设计实现 CF 引导机制的融合，不依赖额外的对比损失函数。

第 4 章 实 验

本章对 COMET 方法进行全面的实验评估。首先介绍实验设置，然后展示主实验结果，接着进行消融实验分析各组件的贡献，最后对语义 ID 的质量进行分析。

4.1 实验设置

4.1.1 数据集

本文在 Amazon Beauty 数据集^[20]上进行实验。该数据集包含美妆类商品的用户交互记录。与已有工作^[3-4]一致，对数据进行 5-core 过滤（丢弃交互次数少于 5 次的用户和物品）。数据集的基本统计信息如表 4.1 所示。

表 4.1 Amazon Beauty 数据集统计

统计量	数值
用户数	22,363
物品数	12,101
交互数	198,502
平均交互长度	8.88

本文关注序列推荐场景，采用 Leave-One-Out 策略划分数据集：每个用户交互序列中，最后一个物品作为测试集，倒数第二个物品作为验证集，其余物品作为训练集。交互序列截断为最近 50 个物品。

4.1.2 评价指标

本文使用 Recall@K 和 NDCG@K 作为评价指标 ($K \in \{5, 10\}$)。

Recall@K 衡量测试集中的目标物品是否出现在推荐列表的前 K 个位置：

$$\text{Recall@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \mathbb{I}(i_u \in \text{Top-}K_u), \quad (4.1)$$

其中 $\mathcal{U}$ 为测试用户集合， i_u 为用户 u 的测试物品，Top- K_u 为用户 u 推荐的前 K 个物品， $\mathbb{I}(\cdot)$ 为指示函数。

NDCG@K (Normalized Discounted Cumulative Gain) 考虑了推荐位置的影响，

表 4.2 COMET 超参数设置

超参数	符号	值
<i>COMET</i> 融合模块		
注意力维度	d_{model}	256
注意力头数	n_{heads}	4
交叉注意力层数	$n_{\text{attn_layers}}$	2
文本 token 数	$n_{\text{text_tokens}}$	4
融合 Dropout	—	0.1
残差向量量化		
码本层数	L	4
每层码本大小	K	256
码本维度	d_e	64
承诺损失权重	β	0.25
EMA 衰减因子	γ_{ema}	0.99
死码阈值	δ	2.0
碰撞优化		
Sinkhorn 层数	—	最后 2 层
Sinkhorn ϵ (L3)	ϵ_3	0.005
Sinkhorn ϵ (L4)	ϵ_4	0.01
最大优化轮数	—	5

位置越靠前权重越高：

$$\text{NDCG}@K = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \frac{\mathbb{I}(i_u \in \text{Top-}K_u)}{\log_2(\text{pos}_u + 1)}, \quad (4.2)$$

其中 pos_u 为目标物品 i_u 在推荐列表中的位置。

所有指标取值越高表示推荐性能越好。

4.1.3 基线方法

本文比较以下语义 ID 构建方法：

- **RQ-KMeans**^[12]：使用 faiss KMeans 直接在原始 4096 维文本嵌入上进行 4 层残差聚类，无学习组件。
- **RQ-VAE**^[5]：使用 MLP 编码器将文本嵌入映射到 64 维隐空间，经 4 层残差向量量化和 MLP 解码器重建。
- **LETTER**^[6]：在 RQ-VAE 基础上引入协同过滤信号。使用预训练的 SASRec 模型提取物品的协同过滤嵌入，通过 InfoNCE 对比损失要求量化后的隐向量与协同过滤嵌入在表示空间中对齐，从而将用户行为模式融入语义 ID 构建过程。
- **COMET**（本文方法）：使用协同引导交叉注意力融合文本、图像和 CF 嵌入，配合文本多 token 投影和多目标重建。

所有方法使用相同的量化配置：4 层码本，每层 256 个码向量，码本维度 64。下游推荐模型的配置保持一致，以确保对比的公平性。

4.1.4 下游推荐模型

COMET 构建的语义 ID 可以直接输入任何基于语义 ID 的生成式推荐模型。本文使用两种代表性模型进行评估。

TIGER。TIGER^[3] 基于标准 T5^[10] 编码器-解码器架构。编码器将用户历史中每个物品的 4 层语义 ID 转化为特殊 token（如 $\langle s_a_3 \rangle$ ）并编码，解码器自回归地逐层生成目标物品的语义 ID。为确保生成的 ID 对应真实物品，TIGER 使用基于前缀树的约束束搜索。

OneRec。OneRec^[12] 采用自定义 Transformer 架构。用户历史序列的语义 ID 嵌入被转换为键值表示，Transformer 层通过交叉注意力查询历史上下文、通过自注意力处理已生成的序列，逐位置自回归生成目标语义 ID。其架构借鉴大语言模型设计，使用 RMSNorm、SiLU 门控 FFN 等技术，模型容量更大。

4.1.5 实现细节

COMET。COMET 的超参数设置如表 4.2 所示。文本、图像嵌入和 CF 引导信息的提取方式及 COMET 融合模块、解码器的架构细节见第 3 章。训练方面，使用 Adam 优化器，训练 300 个周期，批大小 1024，初始学习率 1×10^{-3} ，权重衰减 1×10^{-4} ，梯度裁剪阈值 1.0。学习率采用余弦退火调度 (CosineAnnealingLR)，最小学习率 1×10^{-5} 。从训练的 20% 处开始启用 Sinkhorn 均匀化策略。

基线方法。RQ-KMeans 使用 faiss 库的 KMeans 实现，每层聚类 100 次迭代，无需训练。RQ-VAE 和 LETTER 均使用 2 层 MLP 编码器 ($4096 \rightarrow 1024 \rightarrow 64$) 和对应的 MLP 解码器，训练 300 个周期，学习率 1×10^{-3} ，批大小 1024。LETTER 额外引入 InfoNCE 对比损失，温度参数 $\tau = 0.1$ 。

下游推荐模型。TIGER 使用 Adam 优化器，学习率 5×10^{-4} ，训练 200 个周期。OneRec 使用 AdamW 优化器 (权重衰减 0.1)，学习率 5×10^{-4} 配合 Warmup 余弦衰减调度器，训练 30 个周期。两种模型的批大小均为 256，束搜索宽度为 20，最大序列长度为 50，随机种子为 2025。

4.2 主实验结果

表 4.3 和表 4.4 分别展示了不同语义 ID 构建方法在 TIGER 和 OneRec 模型上的推荐性能。

表 4.3 TIGER 结合不同语义 ID 方法的推荐性能

方法	Recall@5	Recall@10	NDCG@5	NDCG@10
RQ-KMeans ^[12]	0.0372	0.0604	0.0240	0.0314
RQ-VAE ^[5]	0.0384	0.0585	0.0243	0.0308
LETTER ^[6]	0.0389	0.0607	0.0248	0.0317
COMET	0.0393	0.0627	0.0254	0.0330

从实验结果中可以得到以下观察：

(1) COMET 在两种下游生成式推荐模型上均取得了最优或接近最优的性能。在 TIGER 上，COMET 在全部四个指标上均为最优，其中 Recall@10 达到 0.0627，相比次优的 LETTER 提升了 3.3%；NDCG@10 达到 0.0330，相比 LETTER 提升了 4.1%。在 OneRec 上，COMET 的 Recall@5 达到 0.0410，为所有方法中最高，相比 RQ-KMeans 提升了 3.5%。这些结果表明，融合图像信息和协同引导机制构建的语义 ID 能够在不同架构的生成式推荐模型上稳定带来性能增益，验证了 COMET 方

表 4.4 OneRec 结合不同语义 ID 方法的推荐性能

方法	Recall@5	Recall@10	NDCG@5	NDCG@10
RQ-KMeans ^[12]	0.0396	0.0616	0.0276	0.0346
RQ-VAE ^[5]	0.0384	0.0579	0.0264	0.0326
LETTER ^[6]	0.0391	0.0587	0.0263	0.0326
COMET	0.0410	0.0619	0.0275	0.0342

法的通用性。

(2) LETTER 通过引入 CF 对比损失 (InfoNCE) 在 RQ-VAE 基础上改善了性能, 说明协同过滤信号对语义 ID 的构建确实有帮助。然而, LETTER 的 CF 信号仅通过辅助损失间接作用于编码器, 编码器本身仍然只处理文本嵌入。COMET 进一步超越了 LETTER, 在 TIGER 上 Recall@10 从 0.0607 提升至 0.0627, NDCG@10 从 0.0317 提升至 0.0330, 说明将 CF 信号通过交叉注意力机制直接融入编码过程 (架构级融合) 比通过损失函数间接引导 (损失级融合) 更为有效。

(3) RQ-KMeans 虽然不含任何可学习组件, 但方法直观且稳定, 在两种下游模型上均取得了有竞争力的结果, 在 OneRec 上的 NDCG@5 和 NDCG@10 甚至优于其他方法。然而, 由于 RQ-KMeans 直接在原始嵌入上进行聚类, 无法通过损失函数引入协同过滤等额外信号来优化编码质量, 其性能提升空间有限。相比之下, COMET 等可训练方法能够通过图像融合和协同引导机制持续改善语义 ID 的质量。

为更直观地展示 COMET 的优势, 图 4.1 展示了一个具体的推荐案例。该用户的历史交互记录均为美甲相关商品, 包括彩色指甲贴片和装饰品。COMET 推荐的前三个商品均为色彩鲜艳的美甲装饰, 如彩色亮片、粉色系贴纸等, 成功命中了用户的真实购买。相比之下, RQ-VAE 虽然也推荐了美甲相关商品, 但推荐结果以黑色、金属色等深色系为主, 与用户偏好的彩色风格不符, 未能命中真实购买。这一案例表明, COMET 通过融合图像模态, 能够捕捉到商品的细粒度视觉特征如色彩风格, 从而实现更精准的个性化推荐。而仅依赖文本语义的 RQ-VAE 无法区分同类商品的色彩差异, 导致推荐结果与用户偏好不匹配。

图 4.2 展示了另一个案例, 用于说明 CF 引导机制在捕捉商品协同关系方面的作用。该用户的历史交互包括专业化妆箱、面部大刷和十色眼影盘, 表明用户正在构建完整的彩妆工具体系。COMET 推荐的首位商品为眼部精细刷套装, 成功命中用户的真实购买。这一推荐体现了 COMET 对商品间协同互补关系的准确把握: 用户已拥有眼影盘和面部大刷, 自然需要配套的眼部精细刷来完成眼妆细节的刻




图 4.1 COMET 与 RQ-VAE 的推荐对比实例 1。第一行为用户历史交互，第二行为 COMET 推荐结果（红框为真实购买），第三行为 RQ-VAE 推荐结果。

画。相比之下，RQ-VAE 推荐的商品以单支点彩刷、定妆粉饼等基础单品为主，未能推理出用户构建完整工具体系的连带需求。这一对比表明，COMET 通过 CF 引导机制能够从用户的历史行为中学习商品间的高阶协同模式，从而实现更符合用户实际需求的推荐。

4.3 消融实验

为分析 COMET 中图像模态和 CF 引导机制的贡献，本文设计了以下消融变体，在 OneRec 模型上进行评估：

- **文本**：仅使用文本模态。编码器的 KV 上下文仅包含文本的 4 个 token，query 为可学习向量，模型退化为基于交叉注意力架构的纯文本编码器。
- **文本 + 图像**：使用文本和图像模态。编码器的 KV 上下文包含文本的 4 个 token 和图像 token，query 为可学习向量，保留交叉注意力架构但不使用 CF 引导。



图 4.2 COMET 与 RQ-VAE 的推荐对比实例 2。第一行为用户历史交互，第二行为 COMET 推荐结果（红框为真实购买），第三行为 RQ-VAE 推荐结果。

- **文本 + 协同过滤**：使用文本模态和 CF 引导机制。编码器的 KV 上下文仅包含文本的 4 个 token，CF 嵌入作为 query 引导注意力，不使用图像信息。
- **文本 + 图像 + 协同过滤**：完整的 COMET 模型，融合三种模态。

所有变体除消融的组件外，其余超参数与完整 COMET 保持一致。实验结果如表 4.5 所示。

表 4.5 COMET 关键组件的消融实验结果（OneRec）

方法	Recall@5	Recall@10	NDCG@5	NDCG@10
文本	0.0378	0.0572	0.0260	0.0323
文本 + 协同过滤	0.0387	0.0587	0.0266	0.0330
文本 + 图像	0.0393	0.0592	0.0269	0.0333
文本 + 图像 + 协同过滤	0.0410	0.0619	0.0275	0.0342

从消融实验结果中可以得到以下观察：

- (1) 在纯文本基线上引入协同过滤引导机制（文本 + 协同过滤），Recall@10

从 0.0572 提升至 0.0587 (+2.6%)。CF 嵌入编码了用户行为的共现模式，为语义 ID 提供了来自交互数据的监督信号，通过交叉注意力机制实现物品级别的个性化查询，从而提升编码质量。

(2) 在纯文本基线上引入图像模态（文本 + 图像），Recall@10 从 0.0572 提升至 0.0592 (+3.5%)。图像信息补充了物品的视觉外观特征，在 Amazon Beauty 数据集中，同品牌同系列的商品文本描述高度相似，图像是区分这类商品的关键信号。

(3) 同时引入图像模态和协同过滤引导机制（文本 + 图像 + 协同过滤），Recall@10 从 0.0572 提升至 0.0619 (+8.2%)。值得注意的是，联合提升幅度 (+8.2%) 显著大于单独引入 CF (+2.6%) 和图像 (+3.5%) 的提升之和，说明图像信号和 CF 引导机制之间存在互补效应：图像提供了细粒度的视觉区分信息，CF 引导机制提供了行为层面的协同信号，二者共同作用使编码器能够更好地学习物品的多维度表示。

4.4 长尾物品推荐分析

在实际推荐系统中，物品的交互频次往往呈现长尾分布：少数热门物品占据大量交互，而大量长尾物品的交互数据稀疏。长尾物品的推荐质量直接影响推荐系统的多样性和用户体验，但由于训练数据不足，传统方法在长尾物品上的表现往往不佳。本节分析 COMET 在长尾物品推荐上的性能。

本文将训练集中的物品按交互频次排序，将前 20% 的物品定义为热门物品，后 80% 的物品定义为长尾物品。如图 4.3 所示，Amazon Beauty 数据集呈现典型的长尾分布：前 20% 的热门物品 (2,413 个) 占据了 60.1% 的训练集交互，而后 80% 的长尾物品 (9,653 个) 仅占 39.9% 的交互。在测试时，仅保留目标物品 (ground truth) 为长尾物品的测试样本进行评估，以专门衡量模型对长尾物品的推荐能力。

表 4.6 展示了 COMET 和 RQ-VAE 在 OneRec 模型上对热门物品和长尾物品的推荐性能对比。

表 4.6 热门物品与长尾物品推荐性能对比 (OneRec)

物品类型	方法	Recall@5	Recall@10	NDCG@5	NDCG@10
热门物品	RQ-VAE ^[5]	0.0654	0.1034	0.0433	0.0561
	COMET	0.0701	0.1097	0.0449	0.0575
长尾物品	RQ-VAE ^[5]	0.0175	0.0226	0.0133	0.0144
	COMET	0.0184	0.0248	0.0140	0.0161




图 4.3 Amazon Beauty 数据集的长尾分布。

从实验结果可以看出, COMET 在热门物品和长尾物品上均全面优于 RQ-VAE, 但在长尾物品上的性能增益更为显著。具体而言, 在热门物品上, COMET 的 Recall@10 达到 0.1097, 相比 RQ-VAE 的 0.1034 提升了 6.1%; 而在长尾物品上, COMET 的 Recall@10 达到 0.0248, 相比 RQ-VAE 的 0.0226 提升了 9.7%, 显著高于热门物品的提升幅度。对比完整数据集上 6.9% 的整体提升, 长尾物品上的性能增益尤为突出。这一结果表明, COMET 构建的语义 ID 对交互数据稀疏的长尾物品具有更强的表达能力。

COMET 在长尾物品上的优势主要来源于以下两方面:

(1) 多模态信息融合提供了更丰富的语义表示。长尾物品由于交互数据稀疏, 协同过滤信号较弱, 传统方法难以学习到有效的表示。COMET 通过融合文本和图像信息, 即使在协同过滤信号不足的情况下, 仍能从物品的内容特征中提取丰富的语义信息。特别是图像模态, 能够捕捉到文本难以描述的视觉细节, 为长尾物品提供了额外的区分信号。

(2) CF 引导机制增强了长尾物品与热门物品之间的关联学习。虽然长尾物品本身的交互数据稀疏, 但用户的历史行为中往往同时包含热门物品和长尾物品。COMET 的 CF 引导机制通过交叉注意力将协同过滤信号融入编码过程, 使得长尾物品能够借助其与热门物品的共现模式学习到更准确的语义表示。这种迁移学习效应使得 COMET 在长尾物品上的泛化能力更强。

4.5 语义 ID 质量分析

除下游推荐性能外, 本文还从碰撞率的角度分析语义 ID 的内在质量。

在生成式推荐中，模型的输出是一个语义 ID 而非具体物品。当需要将语义 ID 映射回具体物品时，现有方法（包括 TIGER 和 OneRec）采用的策略是：对于共享同一语义 ID 的多个物品，选择在全局交互数据中出现频次最高的物品作为推荐结果。这意味着碰撞组中除频次最高者以外的所有物品都永远不会被推荐到，碰撞直接导致了不可恢复的精度损失。因此，降低碰撞率是提升语义 ID 质量的关键目标。

语义 ID 的碰撞（collision）指多个不同物品被分配了完全相同的 4 层编码。本文使用两个指标衡量碰撞严重程度：

- **碰撞率（Collision Rate）**：因碰撞而无法被唯一标识的物品数占总物品数的比例，即 $(N - N_{\text{unique}})/N$ ，其中 N 为总物品数， N_{unique} 为唯一编码数。碰撞率反映了编码空间中有多少物品因共享编码而“丢失”了独立身份。
- **碰撞物品占比（Collision Item Ratio）**：涉及碰撞的物品数占总物品数的比例。只要一个物品与任何其他物品共享相同编码，就被计入碰撞物品。该指标直接反映有多少物品的推荐会受到碰撞影响。

表 4.7 对比了各语义 ID 构建方法的碰撞统计。

表 4.7 不同语义 ID 方法的碰撞对比

方法	碰撞率	碰撞物品占比
RQ-KMeans ^[12]	8.48%	14.23%
RQ-VAE ^[5]	2.45%	4.48%
LETTER ^[6]	2.26%	3.89%
COMET	1.45%	2.65%

COMET 在所有方法中碰撞率最低，仅为 1.45%，碰撞物品占比仅 2.65%。相比 RQ-KMeans（碰撞率 8.48%、碰撞物品占比 14.23%），COMET 将碰撞率降低了 82.9%。RQ-VAE 和 LETTER 作为可训练方法，碰撞率分别为 2.45% 和 2.26%，已较 RQ-KMeans 大幅改善，说明通过端到端训练优化编码空间确实有助于减少碰撞。LETTER 通过引入协同过滤对比损失进一步降低了碰撞率。COMET 在此基础上再次降低碰撞率至 1.45%，这一改善主要来源于两方面：（1）多模态融合引入了图像和协同过滤信息，为文本描述高度相似的物品提供了额外的区分信号；（2）Sinkhorn 碰撞优化在更丰富的隐空间表示上进行码分配调整，效果更好。

案例分析。图 4.4 展示了一个典型的碰撞消解案例。物品 9055 和物品 9056 是 REVLON Colorburst Lip Butter 系列的两款不同色号唇膏，它们具有相同的品牌、类别、价格区间和几乎完全相同的文本描述，仅色号名称不同（Tutti Frutti 与 Brown



Item 9055

Title: REVLON Colorburst Lip Butter, *Tutti Frutti*, 0.09 Ounce

Brand: Revlon **Price:** \$6.45

Categories: Beauty > Makeup > Lips > Lipstick

Description: Color burst lip butter combines beautiful color with a buttery balm to give you baby soft, healthy glowing lips.

RQ-KMeans SID: (175, 243, 93, 132)

COMET SID: (255, 214, 73, 147)

(a) Tutti Frutti (物品 9055)



Item 9056

Title: REVLON Colorburst Lip Butter, *Brown Sugar*, 0.09 Ounce

Brand: Revlon **Price:** \$5.65

Categories: Beauty > Makeup > Lips > Lipstick

Description: Color burst lip butter combines beautiful color with a buttery balm to give you baby soft, healthy glowing lips.

RQ-KMeans SID: (175, 243, 93, 132)

COMET SID: (255, 214, 73, 176)

(b) Brown Sugar (物品 9056)

图 4.4 冲突率案例分析: 同系列不同色号唇膏的语义 ID 对比

Sugar)。在 RQ-KMeans 方法中，由于仅依赖文本嵌入进行聚类，两者被分配了完全相同的语义 ID (175, 243, 93, 132)，推荐模型无法将它们区分。而在 COMET 中，由于融合了图像嵌入——两款唇膏的颜色外观明显不同（一款为橙色，一款为棕色）——模型能够在最后一层编码上将两者区分开：物品 9055 的语义 ID 为 (255, 214, 73, 147)，物品 9056 为 (255, 214, 73, 176)。前三层编码相同反映了两者的语义相似性，而第四层编码不同则实现了细粒度的物品区分。

4.6 本章小结

本章通过全面的实验评估验证了 COMET 方法的有效性。主实验结果表明，COMET 构建的语义 ID 在 TIGER 和 OneRec 两种生成式推荐模型上均取得了最优的推荐性能，超越了 RQ-KMeans、RQ-VAE 和 LETTER 等基线方法。消融实验表明，图像模态和 CF 引导机制对语义 ID 质量均有显著贡献，且二者之间存在互补效应。长尾物品分析表明，COMET 在长尾物品上的性能增益显著高于完整数据集，验证了多模态融合和 CF 引导机制对交互稀疏物品的有效性。语义 ID 质量分析表明，COMET 的碰撞率在所有方法中最低，有效缓解了因语义 ID 碰撞导致的推荐精度损失。

第 5 章 总结与展望

5.1 工作总结

本文围绕生成式推荐中语义 ID 的构建问题，提出了 COMET (Collaborative-guided Multimodal Encoding Tokenizer) 方法。主要工作和贡献总结如下：

(1) 针对现有语义 ID 构建方法模态利用单一、协同过滤信号融合间接的问题，提出了协同引导交叉注意力融合机制。该机制以协同过滤嵌入为查询，以文本多 token 投影和图像嵌入构成的键值序列为键值对，通过堆叠的交叉注意力和前馈网络自适应地从内容特征中提取推荐相关信息。与 LETTER 的辅助损失方式相比，COMET 将协同过滤信号从损失层面的间接引导提升为架构层面的直接融合，无需引入额外的对比损失函数。

(2) 提出了多目标重建策略，通过三个独立的解码器分支以加权方式同时重建文本、图像和协同过滤嵌入，促进多模态信息在 64 维隐空间中的均衡编码。配合余弦退火学习率调度和训练时 Sinkhorn 均匀化等训练策略，进一步提升了语义 ID 的质量。

(3) 搭建了从数据处理、多模态嵌入提取、语义 ID 构建到生成式推荐的完整实验流水线，实现了 RQ-KMeans、RQ-VAE、LETTER 和 COMET 四种语义 ID 构建方法在 TIGER 和 OneRec 两种生成式推荐模型上的公平对比。实验结果表明，COMET 在所有设置下均取得了最优的推荐性能。

5.2 未来展望

尽管 COMET 取得了较好的实验结果，仍有以下方向值得进一步探索：

(1) **更多模态的融入**。当前 COMET 融合了文本、图像和协同过滤三种模态。在实际应用中，物品还可能具有其他模态信息（如视频、评论文本情感、价格区间等），交叉注意力架构天然支持扩展更多的 Key-Value token，未来可以探索更丰富的模态融合。

(2) **端到端联合训练**。当前 COMET 的语义 ID 构建和下游生成模型是分阶段训练的。将两者端到端联合优化可能进一步提升性能，使语义 ID 的构建直接面向推荐目标进行优化。

(3) **更大规模数据集验证**。当前实验仅在 Amazon Beauty 数据集上进行。未来应在更多领域和更大规模的数据集上验证 COMET 的泛化能力。

参考文献

- [1] HIDASI B, KARATZOGLOU A, BALTRUNAS L, et al. Session-based recommendations with recurrent neural networks[C]//International Conference on Learning Representations (ICLR). 2016.
- [2] KANG W C, MCAULEY J. Self-attentive sequential recommendation[C]//IEEE International Conference on Data Mining (ICDM). 2018: 197-206.
- [3] RAJPUT S, MEHTA N, SINGH A, et al. Recommender systems with generative retrieval[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023.
- [4] ZHENG B, HOU Y, LU H, et al. Adapting large language models by integrating collaborative semantics for recommendation[C]//IEEE International Conference on Data Engineering (ICDE). 2024.
- [5] LEE D, KIM C, KIM S, et al. Autoregressive image generation using residual quantization[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 11523-11532.
- [6] WANG W, BAO H, LIN X, et al. Learnable item tokenization for generative recommendation[C]//ACM International Conference on Information and Knowledge Management (CIKM). 2024: 2400-2409.
- [7] RENDLE S, FREUDENTHALER C, SCHMIDT-THIEME L. Factorizing personalized Markov chains for next-basket recommendation[C]//International Conference on World Wide Web (WWW). 2010: 811-820.
- [8] TANG J, WANG K. Personalized top-N sequential recommendation via convolutional sequence embedding[C]//ACM International Conference on Web Search and Data Mining (WSDM). 2018: 565-573.
- [9] SUN F, LIU J, WU J, et al. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformers[C]//ACM International Conference on Information and Knowledge Management (CIKM). 2019: 1441-1450.
- [10] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2020, 21(140): 1-67.
- [11] GENG S, LIU S, FU Z, et al. Recommendation as language processing (RLP): A unified pre-train, personalized prompt & predict paradigm (P5)[C]//ACM Conference on Recommender Systems (RecSys). 2022: 299-315.
- [12] ZHOU G, DENG J, ZHANG J, et al. OneRec technical report[A/OL]. 2025. <https://arxiv.org/abs/2506.13695>.
- [13] ZHANG B, SENNRICH R. Root mean square layer normalization[C]//Advances in Neural Information Processing Systems (NeurIPS). 2019.

- [14] SHAZEER N. GLU variants improve transformer[A/OL]. 2020. <https://arxiv.org/abs/2002.05202>.
- [15] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International Conference on Machine Learning (ICML). 2021: 8748-8763.
- [16] ZHAI J, MAI Z F, WANG C D. Multimodal quantitative language for generative recommendation[C]//International Conference on Learning Representations (ICLR). 2025.
- [17] HUANG H, GAI L. Q-BERT4Rec: Quantized semantic-ID representation learning for multimodal recommendation[A/OL]. 2025. <https://arxiv.org/abs/2512.02474>.
- [18] ZHANG Y, LI M, LONG D, et al. Qwen3-embedding: Advancing text embedding and reranking through foundation models[A/OL]. 2025. <https://arxiv.org/abs/2506.05176>.
- [19] CUTURI M. Sinkhorn distances: Lightspeed computation of optimal transport[C]//Advances in Neural Information Processing Systems (NeurIPS). 2013: 2292-2300.
- [20] MCAULEY J, TARGETT C, SHI Q, et al. Image-based recommendations on styles and substitutes[C]//International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR). 2015: 43-52.

致 谢

行文至此，本科四年的求学之旅即将告一段落。回首来路，感慨良多。犹记初入校园时，面对全新专业的迷茫与数理课程的艰深，我曾数次在挫败中自我怀疑。但正是心底那份对知识的渴求与不甘落后的韧劲，让我顶住压力、咬牙坚持，在一次次挑灯夜读、代码调试与反复推演中逐渐拨开迷雾，完成了从懵懂新生到具备专业素养的毕业生的蜕变。在此，我也想郑重感谢那个未曾轻言放弃的自己。这一路的成长，离不开软件学院优良学风的熏陶与包容。感谢学院诸位任课教师严谨治学、精心备课，为我构筑了扎实的专业知识体系；感谢辅导员老师们在日常学习与生活中给予的耐心指导与温暖关怀，为我们排忧解难、保驾护航；更感谢一路同行的同窗挚友，是你们的陪伴与互助，让我们在攻克课业难题、完成项目实战的日夜中彼此支撑、共同进步。这段时光，终将成为我青春里最坚实的底色。

在此，衷心感谢我的毕业论文指导教师张慧老师。从选题的初步确定，到实验方案的细化与完善，再到论文撰写与答辩准备阶段的反复检查与修改，张老师始终以耐心、专业的态度给予我切实的指导。每当研究遇到瓶颈时，老师总能及时给出建议，帮我理清思路，最终使我顺利完成本篇论文。更让我感到踏实与庆幸的是，未来我将继续跟随张老师攻读硕士学位。在接下来的科研学习中，我会保持踏实认真的态度，稳步提升自己的专业能力，努力做好每一项工作，不辜负老师的悉心指导与期望。

当前，人工智能技术正以前所未有的速度重塑各行业图景，而软件工程恰是支撑这一变革的重要基石。站在本科毕业与研究生阶段的新起点上，我期盼未来的求学与职业生涯能够行稳致远。无论技术浪潮如何演进，我愿始终保有初入专业时的踏实与热忱，不忘初心，稳步前行。期待能将所学扎实应用于实践，在人工智能的发展进程中尽己所能，也为社会的持续进步贡献一份绵薄而坚实的力量。

声 明

本人郑重声明：所呈交的综合论文训练论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：_____ 日 期：_____