



清华大学

综合论文训练

基于协同引导的多模态生成式推荐方法研究

系 别： 软件学院

专 业： 软件工程

姓 名： 张 镕 州

指导教师： 张 慧 副研究员

二〇二六年四月

关于论文使用授权的说明

本人完全了解清华大学有关保留、使用综合论文训练论文的规定，即：学校有权保留论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

作者签名：

导师签名：

日 期：

日 期：

摘 要

生成式推荐是一种将推荐问题转化为序列生成任务的新范式，其核心在于为每个物品构建高质量的语义 ID (Semantic ID)。现有的语义 ID 构建方法，如 RQ-VAE 仅利用文本语义信息进行向量量化，而 LETTER 虽然通过辅助对比损失引入了协同过滤信号，但其融合方式较为间接，且均未考虑视觉模态的信息。针对上述不足，本文提出了 COMET (Collaborative-guided Multimodal Encoding Tokenizer)，一种基于协同过滤引导的多模态语义 ID 构建方法。COMET 的核心是一个 CF-as-Query 跨注意力融合模块：以协同过滤嵌入作为查询向量，以文本多 token 投影和图像嵌入构成的键值序列为键值对，通过堆叠的跨注意力和前馈网络自适应地从文本和视觉特征中提取对推荐有用的信息。同时，COMET 采用多目标重建策略，以加权方式同时重建文本、图像和协同过滤嵌入，促进多模态信息在隐空间中的均衡编码。在 Amazon Beauty 数据集上的实验表明，基于 COMET 构建的语义 ID 在 TIGER 和 OneRec 两种主流生成式推荐模型上均取得了优于 RQ-KMeans、RQ-VAE 和 LETTER 的推荐性能。

关键词：生成式推荐；语义 ID；多模态融合；协同过滤；残差向量量化

Abstract

Generative recommendation is an emerging paradigm that formulates the recommendation task as a sequence generation problem, where the quality of item Semantic IDs (SIDs) plays a critical role. Existing SID construction methods such as RQ-VAE rely solely on textual semantics for vector quantization, while LETTER introduces collaborative filtering signals through an auxiliary contrastive loss in an indirect manner, and neither incorporates visual modality information. To address these limitations, this thesis proposes COMET (Collaborative-guided Multimodal Encoding Tokenizer), a multimodal SID construction method guided by collaborative filtering. The core of COMET is a CF-as-Query cross-attention fusion module that uses collaborative filtering embeddings as queries and a key-value sequence composed of multi-token text projections and image embeddings, adaptively extracting recommendation-relevant information from textual and visual features through stacked cross-attention and feed-forward layers. Furthermore, COMET adopts a multi-target reconstruction strategy that simultaneously reconstructs text, image, and collaborative filtering embeddings with weighted losses, promoting balanced multimodal encoding in the latent space. Experiments on the Amazon Beauty dataset demonstrate that SIDs constructed by COMET achieve superior recommendation performance over RQ-KMeans, RQ-VAE, and LETTER on both the TIGER and OneRec generative recommendation models.

Keywords: Generative Recommendation; Semantic ID; Multimodal Fusion; Collaborative Filtering; Residual Vector Quantization

目 录

第 1 章 绪 论.....	1
1.1 研究背景与意义	1
1.2 研究内容与创新点	2
1.3 论文组织结构	2
第 2 章 相关工作.....	4
2.1 序列推荐	4
2.2 生成式推荐	4
2.3 语义 ID 构建方法.....	5
2.3.1 RQ-VAE	5
2.3.2 LETTER.....	6
2.4 多模态推荐	6
第 3 章 基于协同引导的多模态语义 ID 构建方法	8
3.1 问题定义	8
3.1.1 序列推荐	8
3.1.2 语义 ID	8
3.1.3 生成式推荐	8
3.2 整体框架	8
3.3 多模态嵌入提取	9
3.3.1 文本嵌入	9
3.3.2 图像嵌入	10
3.3.3 协同过滤嵌入	10
3.4 COMET 融合模块	10
3.4.1 模态投影	10
3.4.2 CF-as-Query 跨注意力.....	11
3.4.3 融合 MLP	11
3.5 残差向量量化	12
3.5.1 指数移动平均码本更新	12
3.5.2 死码重启	12
3.5.3 码本多样性损失	12
3.5.4 KMeans 码本初始化	12

3.6 训练策略	13
3.6.1 损失函数	13
3.6.2 优化器与训练细节	13
3.7 Sinkhorn 碰撞优化	14
3.8 下游生成式推荐模型	14
3.8.1 TIGER	15
3.8.2 OneRec	15
3.9 本章小结	15
第 4 章 实 验	16
4.1 实验设置	16
4.1.1 数据集	16
4.1.2 评价指标	16
4.1.3 基线方法	16
4.1.4 实现细节	18
4.2 主实验结果	18
4.3 消融实验	19
4.4 语义 ID 质量分析	20
4.5 本章小结	23
第 5 章 总结与展望	24
5.1 工作总结	24
5.2 未来展望	24
参考文献	25
致 谢	27
声 明	28

插图清单

图 3.1 COMET 整体框架	9
图 4.1 碰撞消解案例：同系列不同色号唇膏。两者文本描述几乎完全相同，RQ-KMeans 分配了相同的 SID；COMET 通过融合图像信息，在第四层编码上将两者区分（加粗标注）。	22

附表清单

表 4.1 Amazon Beauty 数据集统计	16
表 4.2 COMET 超参数设置	17
表 4.3 TIGER 结合不同语义 ID 方法的推荐性能	18
表 4.4 OneRec 结合不同语义 ID 方法的推荐性能	19
表 4.5 模态消融实验 (OneRec)	20
表 4.6 不同语义 ID 方法的碰撞对比	21

第 1 章 绪 论

1.1 研究背景与意义

推荐系统是现代互联网平台的核心技术之一，旨在从海量候选物品中为用户筛选出可能感兴趣的内容。随着电子商务、社交媒体和内容平台的快速发展，推荐系统在提升用户体验和商业价值方面发挥着日益重要的作用。

序列推荐 (Sequential Recommendation) 是推荐系统领域的重要研究方向，其核心思想是根据用户的历史交互序列预测其下一个可能交互的物品。传统的序列推荐方法，如基于循环神经网络的 GRU4Rec^[1] 和基于自注意力机制的 SASRec^[2]，通过学习物品 ID 的嵌入表示来建模用户偏好的动态变化。然而，这类方法依赖于独立的物品 ID 嵌入，无法建模物品之间的语义关联，且对新物品的泛化能力有限。

近年来，生成式推荐 (Generative Recommendation) 作为一种新范式受到了广泛关注^[3-4]。其核心思想是：首先为每个物品分配一个由多层离散编码组成的语义 ID (Semantic ID)，然后将推荐问题转化为序列到序列的生成任务——给定用户历史交互物品的语义 ID 序列，自回归地生成下一个物品的语义 ID。与传统方法相比，生成式推荐具有以下优势：(1) 语义 ID 编码了物品的内容特征，语义相似的物品拥有相近的编码，有助于知识迁移；(2) 生成式框架天然支持开放词汇，对新物品具有更好的泛化性；(3) 多层级的编码结构实现了从粗到细的物品检索。

在生成式推荐框架中，语义 ID 的构建质量直接决定了推荐性能的上限。目前主流的语义 ID 构建方法基于残差量化变分自编码器 (RQ-VAE)^[3,5]，将物品的文本嵌入通过编码器映射到低维隐空间，再经过多层残差向量量化生成离散编码。然而，现有方法在模态利用和信号融合方面存在明显不足：

第一，**模态利用单一**。主流方法仅利用文本语义信息构建语义 ID。以 TIGER^[3] 为代表的方法使用预训练语言模型提取物品文本嵌入，然后直接进行向量量化。然而，在电商等场景中，物品的视觉外观往往是影响用户决策的关键因素，忽视图像信息会导致语义 ID 无法全面描述物品特征。

第二，**协同过滤信号融合不够直接**。LETTER^[4] 率先尝试在语义 ID 构建中引入协同过滤 (Collaborative Filtering, CF) 信号，通过在 RQ-VAE 的训练损失中添加 InfoNCE 对比损失来对齐量化后的隐向量与 CF 嵌入。这种通过辅助损失间接融合的方式需要额外引入对比损失函数并仔细调节其权重，融合程度难以控制等问题。

第三，**缺乏有效的多模态融合机制**。现有的语义 ID 构建工作尚未探索如何将文本、图像和协同过滤三种异构模态有效融合到统一的语义 ID 表示中。简单的特

征拼接或加权平均无法捕捉模态间的复杂交互关系。

1.2 研究内容与创新点

针对上述问题,本文提出了 COMET (Collaborative-guided Multimodal Encoding Tokenizer), 一种基于协同过滤引导的多模态语义 ID 构建方法。本文的主要研究内容和创新点包括:

(1) 提出了 **CF-as-Query 跨注意力融合机制**。COMET 将协同过滤嵌入作为注意力查询 (Query), 将文本多 token 投影和图像嵌入构成的键值序列作为键值对 (Key-Value), 通过多层堆叠的跨注意力和前馈网络实现三模态深度融合。文本嵌入被分割为 4 个子空间分别投影, 形成 4 个 KV token, 使注意力能够细粒度地选择文本信息。这一设计的直觉在于: 协同过滤信号反映了用户群体的行为偏好, 用其作为查询可以自适应地从文本和视觉特征中提取对推荐最有价值的信息。与 LETTER 的辅助损失方式相比, COMET 将协同过滤信号通过模型架构直接融入编码过程, 无需引入额外的对比损失函数及其权重调节。

(2) 提出**多目标重建策略促进多模态信息均衡编码**。COMET 采用三个独立的解码器分支, 以加权方式同时重建文本、图像和协同过滤三种模态的嵌入。文本嵌入作为维度最高、信息量最丰富的模态赋予最大权重, 图像和协同过滤嵌入的重建起正则化作用, 迫使隐向量在编码文本语义的同时保留视觉和协同过滤信号, 实现多模态信息在隐空间中的均衡编码。

(3) 构建了**完整的多模态生成式推荐实验框架**。本文搭建了从原始数据处理、多模态嵌入提取、语义 ID 构建到生成式推荐模型训练和评估的完整实验流水线, 实现了 RQ-KMeans、RQ-VAE、LETTER 和 COMET 四种语义 ID 构建方法的公平对比, 并在 TIGER 和 OneRec 两种代表性生成式推荐模型上验证了 COMET 的有效性。

1.3 论文组织结构

本文的组织结构如下:

第一章为绪论, 介绍研究背景、问题提出和主要创新点。

第二章为相关工作, 综述序列推荐、生成式推荐、语义 ID 构建和多模态推荐的相关研究。

第三章为方法, 详细描述 COMET 的整体框架, 包括多模态嵌入提取、CF-as-Query 跨注意力融合模块、多目标重建、残差向量量化、训练策略和碰撞优化

等。

第四章为实验，在 **Amazon Beauty** 数据集上全面的实验评估，包括主实验、消融实验和语义 ID 质量分析。

第五章为总结与展望，总结本文的工作并讨论未来的研究方向。

第 2 章 相关工作

本章对与本文研究相关的工作进行综述，主要包括序列推荐、生成式推荐、语义 ID 构建方法和多模态推荐四个方面。

2.1 序列推荐

序列推荐旨在根据用户的历史交互序列建模其动态偏好，预测下一个可能交互的物品。早期的序列推荐方法基于马尔可夫链，假设下一个交互仅依赖于最近的少量交互^[6]。随着深度学习的发展，基于神经网络的序列推荐方法取得了显著进展。

GRU4Rec^[1]首次将门控循环单元（GRU）引入基于会话的推荐，通过循环神经网络建模交互序列的时序依赖关系。Caser^[7]则从另一个角度出发，将用户的近期交互嵌入矩阵视为“图像”，利用卷积神经网络捕捉序列中的局部模式。

SASRec^[2]是序列推荐领域的里程碑工作，它将自注意力机制引入序列推荐，通过单向 Transformer 编码器对用户历史交互序列进行建模。SASRec 使用因果注意力掩码确保每个位置只关注之前的交互，有效捕捉了长距离依赖关系。在此基础上，BERT4Rec^[8]借鉴 BERT 的掩码语言模型思想，采用双向自注意力和完形填空训练策略，在部分场景下取得了进一步提升。

值得注意的是，上述方法均基于独立的物品 ID 进行嵌入学习，物品之间的语义关联完全依赖于协同过滤信号通过训练隐式习得。这种方式在冷启动场景下表现不佳，且无法利用物品的内容信息。本文使用 SASRec 作为协同过滤嵌入的提取器，其学习到的物品嵌入编码了用户行为模式中的协同信号，为 COMET 融合模块提供了重要的输入。

2.2 生成式推荐

生成式推荐将推荐问题重新表述为序列生成任务，其灵感源自信息检索领域的可微搜索索引（Differentiable Search Index, DSI）^[9]。DSI 的核心思想是训练一个 Transformer 模型直接将查询映射为文档标识符，无需传统的索引-检索两阶段流程。生成式推荐将这一思想迁移到推荐场景：将物品映射为离散的语义 ID，训练生成模型根据用户历史自回归地生成目标物品的语义 ID。

TIGER^[3]是生成式推荐的代表性工作。它使用 RQ-VAE 将物品的文本嵌入量

化为多层语义 ID，然后基于 T5^[10] 编码器-解码器架构，将用户历史中所有物品的语义 ID 拼接为输入序列，自回归地生成目标物品的 4 层语义 ID。TIGER 还提出了基于前缀树（Trie）的约束束搜索，确保生成的语义 ID 序列一定对应某个真实物品，有效避免了无效生成。

P5^[11] 从另一个角度探索生成式推荐，将多种推荐任务（评分预测、序列推荐、解释生成等）统一为自然语言生成任务，使用单一的 T5 模型处理。LC-Rec^[4] 在此基础上提出了 LETTER 语义 ID 构建方法和对齐-生成两阶段训练范式。

OneRec^[12] 是另一种代表性的生成式推荐模型，采用了不同于 T5 的自定义 Transformer 架构。OneRec 使用跨注意力机制将用户历史编码为键值（Key-Value）缓存，解码器通过跨注意力查询历史上下文并自回归生成目标语义 ID。其架构借鉴了大语言模型的设计，使用 RMSNorm^[13]、SiLU 门控前馈网络^[14] 和更大的模型容量（1024 维、12 层）。OneRec 还提出了预裁剪（Precut）策略加速束搜索，在每一步先筛选概率最高的候选 token 再进行束扩展。

生成式推荐的性能很大程度上取决于语义 ID 的质量。如果语义 ID 不能有效编码物品特征，生成模型即使结构再先进也难以学习到有效的推荐模式。因此，本文聚焦于语义 ID 构建方法的改进。

2.3 语义 ID 构建方法

语义 ID 构建的目标是为每个物品分配一个由多层离散编码组成的标识符，使得语义相似的物品具有相近的编码。目前主流的方法基于残差量化（Residual Quantization）。

2.3.1 RQ-VAE

残差量化变分自编码器（RQ-VAE）^[5] 是语义 ID 构建的基础框架。其结构包含编码器、残差向量量化器和解码器三部分。

编码器将物品的高维嵌入（如 4096 维的文本嵌入）通过多层感知机映射到低维隐向量 $\mathbf{z} \in \mathbb{R}^d$ （如 $d = 32$ ）。残差向量量化器包含 L 层（通常 $L = 4$ ），每层维护一个码本 $\mathbf{C}^{(l)} = \{\mathbf{c}_1^{(l)}, \dots, \mathbf{c}_K^{(l)}\} \subset \mathbb{R}^d$ （ K 通常为 256）。量化过程按层级进行：

$$\mathbf{r}^{(0)} = \mathbf{z}, \quad (2.1)$$

$$k^{(l)} = \arg \min_k \|\mathbf{r}^{(l-1)} - \mathbf{c}_k^{(l)}\|^2, \quad l = 1, \dots, L, \quad (2.2)$$

$$\mathbf{r}^{(l)} = \mathbf{r}^{(l-1)} - \mathbf{c}_{k^{(l)}}^{(l)}, \quad (2.3)$$

其中 $\mathbf{r}^{(l)}$ 为第 l 层的残差， $k^{(l)}$ 为第 l 层分配的编码索引。物品的语义 ID 即为

$(k^{(1)}, k^{(2)}, \dots, k^{(L)})$ 。

解码器将量化后的表示 $\hat{\mathbf{z}} = \sum_{l=1}^L \mathbf{c}_{k^{(l)}}^{(l)}$ 重建为原始嵌入。训练损失为重建损失与承诺损失（commitment loss）之和：

$$\mathcal{L}_{\text{RQ-VAE}} = \|\mathbf{x}_{\text{rec}} - \mathbf{x}\|^2 + \beta \sum_{l=1}^L \|\mathbf{r}^{(l-1)} - \text{sg}[\mathbf{c}_{k^{(l)}}^{(l)}]\|^2, \quad (2.4)$$

其中 $\text{sg}[\cdot]$ 表示停止梯度操作， β 为承诺损失权重。码本通过指数移动平均（EMA）更新，并配合死码重启机制维持码本利用率。

2.3.2 LETTER

LETTER^[4]在 RQ-VAE 的基础上做了两项重要改进：

第一，引入协同过滤对比损失。LETTER 使用预训练的 SASRec 模型提取物品的协同过滤嵌入 $\mathbf{e}_{\text{cf}}$ ，然后在训练损失中添加 InfoNCE 对比损失：

$$\mathcal{L}_{\text{cf}} = -\log \frac{\exp(\text{sim}(\hat{\mathbf{z}}, \mathbf{e}_{\text{cf}})/\tau)}{\sum_{j=1}^B \exp(\text{sim}(\hat{\mathbf{z}}, \mathbf{e}_{\text{cf},j})/\tau)}, \quad (2.5)$$

其中 $\text{sim}(\cdot, \cdot)$ 为余弦相似度， $\tau = 0.07$ 为温度参数， B 为批大小。这一损失要求量化后的语义表示与对应的协同过滤嵌入在表示空间中对齐。为避免对比损失干扰编码器和码本的初始化，LETTER 采用了预热-渐变调度：前 50 个训练周期不使用 CF 损失，之后在 50 个周期内线性增加其权重至目标值。

第二，码本多样性损失。LETTER 对每层码本的码向量进行 KMeans 聚类，然后在同一聚类内的码向量之间施加对比学习损失，鼓励聚类内部的码向量保持可区分性，促进码本的充分利用。

LETTER 的总损失为：

$$\mathcal{L}_{\text{LETTER}} = \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{vq}} + \alpha \mathcal{L}_{\text{cf}} + \gamma \mathcal{L}_{\text{div}}, \quad (2.6)$$

其中 α 为 CF 损失权重（经调度后为 0.05）， γ 为多样性损失权重（0.0001）。

LETTER 的局限性在于：CF 信号仅通过辅助损失间接影响编码过程，需要额外引入对比损失函数并仔细调节其权重；同时仍仅使用文本模态作为编码器输入，未利用图像信息。

2.4 多模态推荐

多模态信息在推荐系统中的应用由来已久。VBPR^[15]最早将视觉特征引入协同过滤，使用预训练 CNN 提取物品图像特征并与 ID 嵌入融合进行推荐。此后，大量工作探索了将文本、图像、音频等多模态信息融入推荐模型的方法^[16-17]。

近年来，随着预训练多模态模型（如 CLIP^[18]）的发展，多模态推荐进入了新阶段。CLIP 通过对比学习在大规模图文对上训练，能够提取具有跨模态对齐能力的视觉表示，被广泛应用于多模态推荐中的图像特征提取。

然而，现有的多模态推荐工作主要集中在推荐模型层面（如何在协同过滤或序列推荐模型中融合多模态特征），**尚未有工作探索在语义 ID 构建阶段融合多模态信息**。这正是本文工作的切入点：在语义 ID 的编码阶段就将文本、图像和协同过滤信号有效融合，使生成的语义 ID 同时编码多种模态的信息。

第 3 章 基于协同引导的多模态语义 ID 构建方法

本章详细介绍本文提出的 COMET (Collaborative-guided Multimodal Encoding Tokenizer) 方法。首先给出问题定义，然后描述整体框架，接着分别介绍多模态嵌入提取、COMET 融合模块、残差向量量化以及训练与碰撞优化策略。

3.1 问题定义

3.1.1 序列推荐

设物品集合为 $\mathcal{I} = \{i_1, i_2, \dots, i_N\}$ ，用户集合为 $\mathcal{U} = \{u_1, u_2, \dots, u_M\}$ 。每个用户 u 有一个按时间排序的交互序列 $S_u = [s_1, s_2, \dots, s_T]$ ，其中 $s_t \in \mathcal{I}$ 。序列推荐的目标是根据 S_u 预测用户下一个将要交互的物品 s_{T+1} 。

3.1.2 语义 ID

语义 ID 是将每个物品映射为一个 L 层离散编码的表示：

$$\text{SID}(i) = (c_1, c_2, \dots, c_L), \quad c_l \in \{0, 1, \dots, K-1\}, \quad (3.1)$$

其中 L 为编码层数， K 为每层的码本大小。在本文的实验设置中， $L = 4$ ， $K = 256$ 。语义 ID 的构建应满足以下性质：(1) 语义相似的物品具有相近的编码，(2) 不同物品尽量具有不同的编码（低碰撞率），(3) 编码层级从粗到细，第一层捕捉物品的大类别，后续层逐步细化。

3.1.3 生成式推荐

生成式推荐将序列推荐重新表述为序列到序列的生成任务。给定用户交互历史 $S_u = [s_1, \dots, s_T]$ ，将每个物品替换为其语义 ID，得到输入序列：

$$\mathbf{X} = [\text{SID}(s_1); \text{SID}(s_2); \dots; \text{SID}(s_T)]. \quad (3.2)$$

生成模型的目标是自回归地生成目标物品的语义 ID：

$$P(s_{T+1} | S_u) = \prod_{l=1}^L P(c_l | \mathbf{X}, c_1, \dots, c_{l-1}). \quad (3.3)$$

3.2 整体框架

COMET 的整体框架如图 3.1 所示。整个流水线包括以下阶段：

1. **多模态嵌入提取**：分别使用 Qwen3-Embedding-8B、CLIP ViT-L/14 和 SASRec 提取物品的文本嵌入（4096 维）、图像嵌入（768 维）和协同过滤嵌入（128 维）。
2. **COMET 融合编码**：通过 CF-as-Query 跨注意力机制将三种模态嵌入融合为 64 维隐向量。
3. **残差向量量化**：将隐向量通过 4 层残差量化生成离散的 4 层语义 ID。
4. **训练优化**：通过多目标重建损失和量化损失联合训练，使用余弦退火学习率调度，并在训练后期启用 Sinkhorn 均匀化约束，训练后进行 Sinkhorn 碰撞优化。
5. **下游生成推荐**：将构建的语义 ID 输入 TIGER 或 OneRec 进行生成式推荐。




图 3.1 COMET 整体框架

3.3 多模态嵌入提取

COMET 的输入由三种模态的物品嵌入组成，分别编码了物品的文本语义、视觉外观和协同过滤信号。

3.3.1 文本嵌入

文本嵌入是语义 ID 的核心信息来源。本文为每个物品构建结构化的文本描述，包含标题、品牌、价格、商品描述和类别信息，格式如下：

Title: <标题>

Brand: <品牌>

Price: \$<价格>

Description: <商品描述>

Categories: <类别1> > <类别2> > <类别3>

使用 Qwen3-Embedding-8B^[19] 作为文本编码器。该模型是一个 80 亿参数的文本嵌入模型，通过 last-token 池化提取 4096 维的密集表示。在推理时，为输入文本添加指令前缀 “Represent the item description for recommendation:” 以引导模型关注推荐相关的语义信息。

3.3.2 图像嵌入

图像嵌入补充了物品的视觉外观信息。在电商场景中，商品图片直观展示了颜色、形状、材质等文本难以精确描述的属性，对用户的购买决策具有重要影响。

本文使用 CLIP ViT-L/14^[18] 作为图像编码器。CLIP 通过在 4 亿图文对上进行对比学习，其视觉编码器能够提取具有语义理解能力的 768 维图像表示。对于少量缺失图像的物品（Amazon Beauty 数据集中约 8 个物品），使用零向量作为占位，并在 COMET 融合模块中通过可学习填充向量处理。

3.3.3 协同过滤嵌入

协同过滤嵌入编码了物品在用户行为空间中的表示，反映了”购买了 A 的用户也倾向于购买 B” 这类协同信号。

本文使用预训练的 SASRec^[2] 模型提取协同过滤嵌入。SASRec 在用户交互序列上通过交叉熵损失训练，其物品嵌入表 $\mathbf{E} \in \mathbb{R}^{N \times d_{cf}}$ 中的每一行编码了对应物品的协同过滤信息。本文使用的 SASRec 模型的隐藏维度 $d_{cf} = 128$ 。

3.4 COMET 融合模块

COMET 的核心创新是 CF-as-Query 跨注意力融合模块（COMETFusion），用于将三种模态的嵌入融合为统一的低维表示。

3.4.1 模态投影

首先，将三种不同维度的模态嵌入投影到统一的注意力操作维度 d_{model} （本文设为 256）。

文本多 token 投影。原始文本嵌入 $\mathbf{e}_{text} \in \mathbb{R}^{4096}$ 维度远高于其他模态，单一线性投影会导致严重的信息压缩损失。为此，COMET 将 4096 维文本嵌入均匀分割为 4 个 1024 维的片段，每个片段使用独立的线性投影映射到 d_{model} 维：

$$\mathbf{e}_{text} = [\mathbf{e}_{text}^{(1)}; \mathbf{e}_{text}^{(2)}; \mathbf{e}_{text}^{(3)}; \mathbf{e}_{text}^{(4)}], \quad \mathbf{e}_{text}^{(j)} \in \mathbb{R}^{1024}, \quad (3.4)$$

$$\mathbf{h}_{\text{text}}^{(j)} = \mathbf{W}_{\text{text}}^{(j)} \mathbf{e}_{\text{text}}^{(j)} + \mathbf{b}_{\text{text}}^{(j)}, \quad \mathbf{W}_{\text{text}}^{(j)} \in \mathbb{R}^{d_{\text{model}} \times 1024}, \quad j = 1, 2, 3, 4. \quad (3.5)$$

这一设计将原始的 1 个文本 KV token 扩展为 4 个 token，每个 token 聚焦于文本嵌入的不同语义子空间，使跨注意力能够更细粒度地选择文本信息。

图像嵌入和协同过滤嵌入的投影方式不变：

$$\mathbf{h}_{\text{image}} = \mathbf{W}_{\text{image}} \mathbf{e}_{\text{image}} + \mathbf{b}_{\text{image}}, \quad \mathbf{W}_{\text{image}} \in \mathbb{R}^{d_{\text{model}} \times 768}, \quad (3.6)$$

$$\mathbf{h}_{\text{cf}} = \mathbf{W}_{\text{cf}} \mathbf{e}_{\text{cf}} + \mathbf{b}_{\text{cf}}, \quad \mathbf{W}_{\text{cf}} \in \mathbb{R}^{d_{\text{model}} \times 128}. \quad (3.7)$$

对于缺失图像的物品，使用可学习的填充向量 $\mathbf{p} \in \mathbb{R}^{768}$ 替代零向量：

$$\mathbf{e}'_{\text{image}} = \begin{cases} \mathbf{e}_{\text{image}}, & \text{if image exists,} \\ \mathbf{p}, & \text{otherwise.} \end{cases} \quad (3.8)$$

3.4.2 CF-as-Query 跨注意力

COMET 融合的关键设计是将协同过滤嵌入作为注意力查询，文本和图像嵌入作为键值对，通过多层 Transformer 解码器块实现深度融合。

查询 (Query)： 投影后的 CF 嵌入 $\mathbf{Q} = \mathbf{h}_{\text{cf}} \in \mathbb{R}^{1 \times d_{\text{model}}}$ 。

键值对 (Key-Value)： 4 个文本 token 和 1 个图像 token 拼接构成 5 个 token 的序列：

$$\mathbf{K} = \mathbf{V} = [\mathbf{h}_{\text{text}}^{(1)}; \mathbf{h}_{\text{text}}^{(2)}; \mathbf{h}_{\text{text}}^{(3)}; \mathbf{h}_{\text{text}}^{(4)}; \mathbf{h}_{\text{image}}] \in \mathbb{R}^{5 \times d_{\text{model}}}. \quad (3.9)$$

多层跨注意力。 COMET 使用 2 层堆叠的 Transformer 解码器块，每层包含跨注意力和前馈网络 (FFN)。设第 i 层输入为 $\mathbf{q}^{(i)}$ ($\mathbf{q}^{(0)} = \mathbf{Q}$)，每层的计算如下：

$$\mathbf{q}'^{(i)} = \mathbf{q}^{(i)} + \text{CrossAttn}^{(i)}(\text{LN}_1^{(i)}(\mathbf{q}^{(i)}), \text{LN}_2^{(i)}(\mathbf{KV})), \quad (3.10)$$

$$\mathbf{q}^{(i+1)} = \mathbf{q}'^{(i)} + \text{FFN}^{(i)}(\text{LN}_3^{(i)}(\mathbf{q}'^{(i)})), \quad (3.11)$$

其中 LN 为层归一化，FFN 为两层线性变换（维度 $d_{\text{model}} \rightarrow 4d_{\text{model}} \rightarrow d_{\text{model}}$ ）加 GELU 激活。跨注意力使用 $n_{\text{heads}} = 4$ 个头， $d_{\text{head}} = 64$ 。

与单层注意力相比，2 层堆叠结构使模型具有更强的模态交互建模能力。第一层可以学习初步的模态选择和信息提取，第二层在此基础上进一步精细融合。每层的残差连接保证了 CF 信号的直接传递。

最终融合输出 $\mathbf{f} = \mathbf{q}^{(2)}$ 经过最终的层归一化后输入融合 MLP。

3.4.3 融合 MLP

归一化后的特征通过两层感知机映射到码本维度 d_e ：

$$\mathbf{z} = \mathbf{W}_2 \cdot \text{GELU}(\mathbf{W}_1 \mathbf{f} + \mathbf{b}_1) + \mathbf{b}_2, \quad (3.12)$$

其中 $\mathbf{W}_1 \in \mathbb{R}^{128 \times 256}$, $\mathbf{W}_2 \in \mathbb{R}^{64 \times 128}$, 最终输出 $\mathbf{z} \in \mathbb{R}^{64}$ 。

3.5 残差向量量化

隐向量 $\mathbf{z}$ 通过 4 层残差向量量化生成离散的语义 ID。量化过程与 RQ-VAE 相同（见第二章），本节重点介绍 COMET 保留的辅助技术。

3.5.1 指数移动平均码本更新

码本不通过梯度更新，而是使用指数移动平均（EMA）跟踪被分配到各码向量的输入分布：

$$\mathbf{n}^{(t)} = \gamma \mathbf{n}^{(t-1)} + (1 - \gamma) \sum_j \mathbf{1}[k_j = k], \quad (3.13)$$

$$\mathbf{m}^{(t)} = \gamma \mathbf{m}^{(t-1)} + (1 - \gamma) \sum_j \mathbf{1}[k_j = k] \cdot \mathbf{r}_j, \quad (3.14)$$

其中 $\gamma = 0.99$ 为衰减因子。码向量更新为 $\mathbf{c}_k = \mathbf{m}_k / \tilde{n}_k$, $\tilde{n}_k$ 经 Laplace 平滑处理。

3.5.2 死码重启

当某个码向量的 EMA 计数低于阈值（ $\delta = 2.0$ ）时，将其替换为当前批次中的一个随机输入向量，并重置计数。这一机制有效防止了码本中出现长期不被使用的“死码”，维持码本的有效利用率。

3.5.3 码本多样性损失

COMET 保留了 LETTER 提出的码本多样性损失。每个训练周期对各层码本进行 KMeans 聚类（10 个聚类），然后在聚类内部施加对比损失：

$$\mathcal{L}_{\text{div}} = -\frac{1}{|\mathcal{V}|} \sum_{i \in \mathcal{V}} \log \frac{\exp(\text{sim}(\mathbf{x}_{q,i}, \mathbf{c}_{p_i}) / \tau_d)}{\sum_{j \neq k_i} \exp(\text{sim}(\mathbf{x}_{q,i}, \mathbf{c}_j) / \tau_d)}, \quad (3.15)$$

其中 p_i 为与 k_i 同聚类的随机正样本码向量索引， $\tau_d = 0.1$ 为温度参数， $\mathcal{V}$ 为有效样本集合。

3.5.4 KMeans 码本初始化

训练开始前，先将所有物品通过 COMET 融合模块得到隐向量 $\mathbf{z}$ ，然后对第一层码本进行 KMeans 初始化，再在残差上依次初始化后续层的码本。KMeans 迭代 100 次以确保收敛。

3.6 训练策略

3.6.1 损失函数

COMET 的训练损失由重建损失和量化损失组成：

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \lambda \mathcal{L}_{\text{vq}}, \quad (3.16)$$

其中 $\lambda = 1.0$ 为量化损失权重。

重建损失采用多目标重建策略，同时重建文本、图像和协同过滤三种模态的嵌入。COMET 使用三个独立的解码器分支：

- **文本解码器**：5 层 MLP ($64 \rightarrow 256 \rightarrow 512 \rightarrow 1024 \rightarrow 2048 \rightarrow 4096$)，重建原始文本嵌入；
- **图像解码器**：2 层 MLP ($64 \rightarrow 256 \rightarrow 768$)，重建原始图像嵌入；
- **CF 解码器**：2 层 MLP ($64 \rightarrow 128 \rightarrow 128$)，重建原始协同过滤嵌入。

中间层使用 ReLU 激活。

重建损失为三个分支的加权均方误差之和：

$$\mathcal{L}_{\text{rec}} = w_{\text{text}} \|\text{Dec}_{\text{text}}(\hat{\mathbf{z}}) - \mathbf{e}_{\text{text}}\|^2 + w_{\text{image}} \|\text{Dec}_{\text{image}}(\hat{\mathbf{z}}) - \mathbf{e}_{\text{image}}\|^2 + w_{\text{cf}} \|\text{Dec}_{\text{cf}}(\hat{\mathbf{z}}) - \mathbf{e}_{\text{cf}}\|^2, \quad (3.17)$$

其中 $\hat{\mathbf{z}}$ 为经直通估计器 (straight-through estimator) 处理后的量化表示， $w_{\text{text}} = 1.0$ ， $w_{\text{image}} = 0.1$ ， $w_{\text{cf}} = 0.1$ 。对于缺失图像的物品，图像重建损失项被掩码 (mask) 为零，不参与梯度计算。

多目标重建的设计动机如下：文本嵌入作为维度最高、信息量最丰富的模态，赋予最大的重建权重 (1.0)，确保隐空间以文本语义为主干。图像和 CF 的重建权重较低 (0.1)，起到正则化作用——迫使隐向量 $\mathbf{z}$ 不仅编码文本信息，还需保留一定的视觉和协同过滤信号，从而实现更均衡的多模态融合。相比仅重建文本嵌入，多目标重建在 64 维隐空间中能更有效地组织多模态信息。

量化损失为 4 层承诺损失和多样性损失的平均值：

$$\mathcal{L}_{\text{vq}} = \frac{1}{L} \sum_{l=1}^L \left[\beta \|\mathbf{r}^{(l-1)} - \text{sg}[\mathbf{c}_{k^{(l)}}^{(l)}]\|^2 + \gamma \mathcal{L}_{\text{div}}^{(l)} \right], \quad (3.18)$$

其中 $\beta = 0.25$ ， $\gamma = 0.0001$ 。

3.6.2 优化器与训练细节

使用 AdamW 优化器，学习率 1×10^{-3} ，权重衰减 1×10^{-4} 。梯度裁剪阈值为 1.0。批大小为 1024，训练 300 个周期。

学习率调度。使用余弦退火调度器 (CosineAnnealingLR)，学习率从初始值

1×10^{-3} 按余弦函数逐渐衰减至 $\eta_{\min} = 1 \times 10^{-5}$ （即初始学习率的 1%）。相比固定学习率，余弦调度在训练后期提供更精细的参数更新，有助于模型收敛到更优解。

训练时 Sinkhorn 均匀化。在训练的最后 20% 周期（即第 241–300 周期），对残差向量量化的码分配启用 Sinkhorn 均匀化约束，促进码本的均匀利用。这一策略在训练阶段就开始减少碰撞，为训练后的 Sinkhorn 碰撞优化提供更好的起点。

模型选择。在训练过程中保存加权重建损失 $\mathcal{L}_{\text{rec}}$ 最低的模型检查点，而非使用总训练损失进行模型选择。这是因为量化损失和多样性损失的波动较大，直接使用总损失可能导致选择到重建质量次优的模型。

与 LETTER 的训练对比。值得注意的是，COMET 不使用 CF 对比损失（InfoNCE）。CF 信号在 COMET 中完全通过跨注意力机制的架构设计融入，不需要额外的对比损失函数及其权重调节。

3.7 Sinkhorn 碰撞优化

训练完成后，对所有物品进行编码，统计语义 ID 的碰撞情况（多个物品共享相同的语义 ID）。对碰撞组进行迭代优化：

在最后两层量化器上启用 Sinkhorn-Knopp 算法^[20]，将码分配问题转化为最优传输问题。对归一化的距离矩阵 $\mathbf{D}$ 进行迭代行列归一化：

$$\mathbf{Q}^{(0)} = \exp(-\mathbf{D}/\epsilon), \quad \mathbf{Q}^{(t)} = \text{RowNorm}(\text{ColNorm}(\mathbf{Q}^{(t-1)})), \quad (3.19)$$

迭代 50 次后， $\mathbf{Q}$ 趋近于均匀分配矩阵，碰撞组中的物品被分配到不同的码上。

与之前仅在最后一层使用统一温度参数的方案不同，COMET 采用**渐进式温度策略**：第 3 层 $\epsilon_3 = 0.005$ ，第 4 层 $\epsilon_4 = 0.01$ 。较浅层使用较小的 ϵ 以保持编码的精确性，较深层使用较大的 ϵ 以允许更灵活的码分配。在最后两层而非仅最后一层启用 Sinkhorn 优化，能够在更大的编码空间中进行碰撞消解，显著提高碰撞消除的有效性。

配合训练时 Sinkhorn 均匀化（见 §3.6.2），训练后的碰撞优化需要调整的码分配数量更少，最多进行 5 轮碰撞优化，目标碰撞率为 5% 以下。

3.8 下游生成式推荐模型

COMET 构建的语义 ID 可以直接输入任何基于语义 ID 的生成式推荐模型。本文使用两种代表性模型进行评估。

3.8.1 TIGER

TIGER^[3] 基于 T5^[10] 编码器-解码器架构。用户历史中每个物品的 4 层语义 ID 被转化为特殊 token（如 $\langle s_a_3 \rangle$ ），拼接后作为编码器输入。解码器自回归生成目标物品的 4 个语义 ID token，并使用基于前缀树的约束束搜索确保输出的合法性。本文使用的 TIGER 配置为：4 层编码器、4 层解码器、模型维度 128、前馈维度 1024、6 个注意力头、束宽 20。

3.8.2 OneRec

OneRec^[12] 采用自定义 Transformer 架构，使用跨注意力机制将用户历史编码为 KV 缓存供解码器查询。其架构借鉴大语言模型设计，使用 RMSNorm、SiLU 门控 FFN 和更大的模型容量（1024 维、12 层、16 头）。OneRec 使用 3 个独立词汇表（第 3 和第 4 位置共享一个词汇表），词汇表大小为 8192，配合预裁剪策略（top-1024）加速束搜索。

3.9 本章小结

本章详细介绍了 COMET 方法的设计细节。COMET 的核心创新在于 CF-as-Query 跨注意力融合机制，将协同过滤信号从辅助损失的间接引导提升为架构级别的直接融合，同时引入文本多 token 投影和图像模态信息，构建了 5 个 KV token 的丰富键值序列。在训练策略上，COMET 采用多目标重建损失（文本 + 图像 + CF）促进多模态信息在隐空间中的均衡编码，使用余弦退火学习率调度和训练时 Sinkhorn 均匀化进一步提升码本质量。与 LETTER 相比，COMET 通过架构设计实现 CF 信号的融合，不依赖额外的对比损失函数。

第 4 章 实 验

本章对 COMET 方法进行全面的实验评估。首先介绍实验设置，然后展示主实验结果，接着进行消融实验分析各组件的贡献，最后对语义 ID 的质量进行分析。

4.1 实验设置

4.1.1 数据集

本文在 Amazon Beauty 数据集^[21]上进行实验。该数据集包含美妆类商品的用户交互记录。与已有工作^[3,22]一致，对数据进行 5-core 过滤（丢弃交互次数少于 5 次的用户和物品）。数据集的基本统计信息如表 4.1 所示。

表 4.1 Amazon Beauty 数据集统计

统计量	数值
用户数	22,363
物品数	12,101
交互数	198,502
平均交互长度	8.88

本文关注序列推荐场景，采用 Leave-One-Out 策略划分数据集：每个用户交互序列中，最后一个物品作为测试集，倒数第二个物品作为验证集，其余物品作为训练集。交互序列截断为最近 50 个物品。

4.1.2 评价指标

本文使用 $\text{Recall}@K$ 和 $\text{NDCG}@K$ 作为评价指标 ($K \in \{5, 10\}$)。所有指标取值越高表示推荐性能越好。

4.1.3 基线方法

本文比较以下语义 ID 构建方法：

- **RQ-KMeans**^[22]：使用 faiss KMeans 直接在原始 4096 维文本嵌入上进行 4 层残差聚类，无学习组件。
- **RQ-VAE**^[5]：使用 MLP 编码器将文本嵌入映射到 64 维隐空间，经 4 层残差向量量化和 MLP 解码器重建。

表 4.2 COMET 超参数设置

超参数	符号	值
<i>COMET</i> 融合模块		
注意力维度	d_{model}	256
注意力头数	n_{heads}	4
跨注意力层数	$n_{\text{attn_layers}}$	2
文本 token 数	$n_{\text{text_tokens}}$	4
融合 Dropout	—	0.1
残差向量量化		
码本层数	L	4
每层码本大小	K	256
码本维度	d_e	64
承诺损失权重	β	0.25
多样性损失权重	γ	0.0001
EMA 衰减因子	γ_{ema}	0.99
死码阈值	δ	2.0
训练		
训练周期	—	300
批大小	—	1024
学习率	—	1×10^{-3}
权重衰减	—	1×10^{-4}
梯度裁剪	—	1.0
学习率调度	—	CosineAnnealingLR
最小学习率	η_{min}	1×10^{-5}
Sinkhorn 训练比例	sk_start_ratio	0.2
碰撞优化		
Sinkhorn 层数	—	最后 2 层
Sinkhorn ϵ (L3)	ϵ_3	0.005
Sinkhorn ϵ (L4)	ϵ_4	0.01
最大优化轮数	—	5
目标碰撞率	—	5%

- **LETTER**^[4]: 在 RQ-VAE 基础上添加 InfoNCE 协同过滤对比损失和码本多样性损失。
- **COMET** (本文方法): 使用 CF-as-Query 跨注意力融合文本、图像和 CF 嵌入, 配合文本多 token 投影和多目标重建。

所有方法使用相同的量化配置: 4 层码本, 每层 256 个码向量, 码本维度 64。下游推荐模型的配置保持一致, 以确保对比的公平性。

4.1.4 实现细节

COMET。COMET 的超参数设置如表 4.2 所示。三种模态嵌入的提取方式及 COMET 融合模块、解码器的架构细节见第三章。

基线方法。RQ-KMeans 使用 faiss 库的 KMeans 实现, 每层聚类 100 次迭代。RQ-VAE 和 LETTER 均使用 2 层 MLP 编码器 ($4096 \rightarrow 1024 \rightarrow 64$) 和对应的 MLP 解码器, 训练 300 个周期, 学习率 1×10^{-3} , 其余量化配置与 COMET 一致。LETTER 额外使用 InfoNCE 对比损失引入协同过滤信号, 温度参数 $\tau = 0.1$ 。

下游推荐模型。TIGER 和 OneRec 的模型架构见第三章 §3.8。训练方面, TIGER 使用 Adam 优化器, 学习率 5×10^{-4} , 训练 200 个周期, 批大小 256, 从第 100 个周期开始每 10 个周期评估一次, 早停耐心为 2。OneRec 使用 AdamW 优化器 (权重衰减 0.1), 学习率 5×10^{-4} , 配合 Warmup 余弦衰减调度器, 训练 30 个周期, 批大小 256。两种模型的束搜索宽度均为 20, 最大序列长度为 50, 随机种子为 2025。所有实验在 8 块 GPU 上使用分布式数据并行 (DDP) 训练。

4.2 主实验结果

表 4.3 和表 4.4 分别展示了不同语义 ID 构建方法在 TIGER 和 OneRec 模型上的推荐性能。

表 4.3 TIGER 结合不同语义 ID 方法的推荐性能

方法	Recall@5	Recall@10	NDCG@5	NDCG@10
RQ-KMeans[J2025]	0.0372	0.0604	0.0240	0.0314
RQ-VAE[Rajput2023]	0.0384	0.0585	0.0243	0.0308
LETTER[Wang2024]	0.0389	0.0607	0.0248	0.0317
COMET	0.0393	0.0627	0.0254	0.0330

从实验结果中可以得到以下观察:

- (1) COMET 在两种下游生成式推荐模型上均取得了最优或接近最优的性能。

表 4.4 OneRec 结合不同语义 ID 方法的推荐性能

方法	Recall@5	Recall@10	NDCG@5	NDCG@10
RQ-KMeans[J2025]	0.0396	0.0616	0.0276	0.0346
RQ-VAE[Rajput2023]	0.0384	0.0579	0.0264	0.0326
LETTER[Wang2024]	0.0391	0.0587	0.0263	0.0326
COMET	0.0410	0.0619	0.0275	0.0342

在 TIGER 上, COMET 在全部四个指标上均为最优, 其中 Recall@10 达到 0.0627, 相比次优的 LETTER 提升了 3.3%; NDCG@10 达到 0.0330, 相比 LETTER 提升了 4.1%。在 OneRec 上, COMET 的 Recall@5 达到 0.0410, 为所有方法中最高, 相比 RQ-KMeans 提升了 3.5%。这些结果表明, 多模态融合构建的语义 ID 能够在不同架构的生成式推荐模型上稳定带来性能增益, 验证了 COMET 方法的通用性。

(2) LETTER 通过引入 CF 对比损失 (InfoNCE) 在 RQ-VAE 基础上改善了性能, 说明协同过滤信号对语义 ID 的构建确实有帮助。然而, LETTER 的 CF 信号仅通过辅助损失间接作用于编码器, 编码器本身仍然只处理文本嵌入。COMET 进一步超越了 LETTER, 在 TIGER 上 Recall@10 从 0.0607 提升至 0.0627, NDCG@10 从 0.0317 提升至 0.0330, 说明将 CF 信号通过跨注意力机制直接融入编码过程 (架构级融合) 比通过损失函数间接引导 (损失级融合) 更为有效。

(3) RQ-KMeans 虽然不含任何可学习组件, 但方法直观且稳定, 在两种下游模型上均取得了有竞争力的结果, 在 OneRec 上的 NDCG@5 和 NDCG@10 甚至优于其他方法。然而, 由于 RQ-KMeans 直接在原始嵌入上进行聚类, 无法通过损失函数引入协同过滤等额外信号来优化编码质量, 其性能提升空间有限。相比之下, COMET 等可训练方法能够通过多模态融合和辅助损失持续改善语义 ID 的质量。

4.3 消融实验

为分析 COMET 中各模态信号的贡献, 本文设计了以下消融变体, 在 OneRec 模型上进行评估:

- **w/o Image**: 去除图像模态。编码器的 KV 上下文仅包含文本的 4 个 token, 不拼接图像 token; 同时去除图像重建损失。
- **w/o CF**: 去除协同过滤信号。将 CF 嵌入作为 query 替换为一个可学习的 query 向量 (所有物品共享), 保留跨注意力架构不变; 同时去除 CF 重建损失。
- **w/o Image & CF**: 同时去除图像模态和 CF 信号。KV 上下文仅包含文本 token, query 为可学习向量, 模型退化为基于跨注意力架构的纯文本编码器。

所有变体除消融的模态外，其余超参数与完整 COMET 保持一致。实验结果如表 4.5 所示。

表 4.5 模态消融实验 (OneRec)

方法	Recall@5	Recall@10	NDCG@5	NDCG@10
COMET	0.0410	0.0619	0.0275	0.0342
w/o Image	0.0387	0.0587	0.0266	0.0330
w/o CF	0.0393	0.0592	0.0269	0.0333
w/o Image & CF	0.0378	0.0572	0.0260	0.0323

从消融实验结果中可以得到以下观察：

(1) 去除图像模态 (w/o Image) 导致 Recall@10 从 0.0619 降至 0.0587 (−5.2%)，NDCG@10 从 0.0342 降至 0.0330 (−3.5%)。这表明图像信息对语义 ID 的构建具有重要贡献。在 Amazon Beauty 数据集中，同品牌同系列的商品（如不同色号的口红）文本描述高度相似，图像是区分这类商品的关键信号。

(2) 去除 CF 信号 (w/o CF) 导致 Recall@10 从 0.0619 降至 0.0592 (−4.4%)，NDCG@10 从 0.0342 降至 0.0333 (−2.6%)。CF 嵌入编码了用户行为的共现模式，为语义 ID 提供了来自交互数据的监督信号。去除 CF 后，原本由 CF 嵌入生成的 query 被替换为一个随机初始化的可学习向量，该向量在所有物品间共享，跨注意力机制失去了物品级别的个性化查询能力，导致对文本和图像信息的聚合变为固定加权。

(3) 同时去除图像和 CF 信号 (w/o Image & CF) 导致最大的性能下降：Recall@10 降至 0.0572 (−7.6%)，NDCG@10 降至 0.0323 (−5.6%)。该变体仅依赖文本信息，其性能降幅 (−5.6%) 大于单独去除图像 (−3.5%) 或 CF (−2.6%) 的降幅之和，说明图像信号和 CF 信号之间存在互补效应：图像提供了细粒度的视觉区分信息，CF 提供了行为层面的协同信号，二者共同作用使编码器能够更好地学习物品的多维度表示。

4.4 语义 ID 质量分析

除下游推荐性能外，本文还从碰撞率的角度分析语义 ID 的内在质量。

在生成式推荐中，模型的输出是一个语义 ID 而非具体物品。当需要将语义 ID 映射回具体物品时，现有方法（包括 TIGER 和 OneRec）采用的策略是：对于共享同一语义 ID 的多个物品，选择在全局交互数据中出现频次最高的物品作为推荐结果。这意味着碰撞组中除频次最高者以外的所有物品都永远不会被推荐到，碰撞

直接导致了不可恢复的精度损失。因此，降低碰撞率是提升语义 ID 质量的关键目标。

语义 ID 的碰撞 (collision) 指多个不同物品被分配了完全相同的 4 层编码。本文使用两个指标衡量碰撞严重程度：

- **碰撞率 (Collision Rate)**：因碰撞而无法被唯一标识的物品数占总物品数的比例，即 $(N - N_{\text{unique}})/N$ ，其中 N 为总物品数， N_{unique} 为唯一编码数。碰撞率反映了编码空间中有多少物品因共享编码而“丢失”了独立身份。
- **碰撞物品占比 (Collision Item Ratio)**：涉及碰撞的物品数占总物品数的比例。只要一个物品与任何其他物品共享相同编码，就被计入碰撞物品。该指标直接反映有多少物品的推荐会受到碰撞影响。

表 4.6 对比了各语义 ID 构建方法的碰撞统计。

表 4.6 不同语义 ID 方法的碰撞对比

方法	碰撞率	碰撞物品占比
RQ-KMeans[J2025]	8.48%	14.23%
RQ-VAE[Rajput2023]	2.45%	4.48%
LETTER[Wang2024]	2.26%	3.89%
COMET	1.45%	2.65%

COMET 在所有方法中碰撞率最低，仅为 1.45%，碰撞物品占比仅 2.65%。相比 RQ-KMeans（碰撞率 8.48%、碰撞物品占比 14.23%），COMET 将碰撞率降低了 82.9%。RQ-VAE 和 LETTER 作为可训练方法，碰撞率分别为 2.45% 和 2.26%，已较 RQ-KMeans 大幅改善，说明通过端到端训练优化编码空间确实有助于减少碰撞。LETTER 通过引入协同过滤对比损失进一步降低了碰撞率。COMET 在此基础上再次降低碰撞率至 1.45%，这一改善主要来源于两方面：（1）多模态融合引入了图像和协同过滤信息，为文本描述高度相似的物品提供了额外的区分信号；（2）Sinkhorn 碰撞优化在更丰富的隐空间表示上进行码分配调整，效果更好。

案例分析。图 4.1 展示了一个典型的碰撞消解案例。物品 9055 和物品 9056 是 REVLON Colorburst Lip Butter 系列的两款不同色号唇膏，它们具有相同的品牌、类别、价格区间和几乎完全相同的文本描述，仅色号名称不同（Tutti Frutti 与 Brown Sugar）。在 RQ-KMeans 方法中，由于仅依赖文本嵌入进行聚类，两者被分配了完全相同的语义 ID (175, 243, 93, 132)，推荐模型无法将它们区分。而在 COMET 中，由于融合了图像嵌入——两款唇膏的颜色外观明显不同（一款为橙色，一款为棕色）——模型能够在最后一层编码上将两者区分开：物品 9055 的语义 ID 为



Item 9055

Title: REVLON Colorburst Lip Butter, *Tutti Frutti*, 0.09 Ounce

Brand: Revlon **Price:** \$6.45

Categories: Beauty > Makeup > Lips > Lipstick

Description: Color burst lip butter combines beautiful color with a buttery balm to give you baby soft, healthy glowing lips.

RQ-KMeans SID: (175, 243, 93, 132)

COMET SID: (255, 214, 73, **147**)

(a) Tutti Frutti (物品 9055)



Item 9056

Title: REVLON Colorburst Lip Butter, *Brown Sugar*, 0.09 Ounce

Brand: Revlon **Price:** \$5.65

Categories: Beauty > Makeup > Lips > Lipstick

Description: Color burst lip butter combines beautiful color with a buttery balm to give you baby soft, healthy glowing lips.

RQ-KMeans SID: (175, 243, 93, 132)

COMET SID: (255, 214, 73, **176**)

(b) Brown Sugar (物品 9056)

图 4.1 碰撞消解案例：同系列不同色号唇膏。两者文本描述几乎完全相同，RQ-KMeans 分配了相同的 SID；COMET 通过融合图像信息，在第四层编码上将两者区分（加粗标注）。

(255, 214, 73, 147), 物品 9056 为 (255, 214, 73, 176)。前三层编码相同反映了两者的语义相似性, 而第四层编码不同则实现了细粒度的物品区分。

4.5 本章小结

本章通过全面的实验评估验证了 COMET 方法的有效性。主实验结果表明, COMET 构建的语义 ID 在 TIGER 和 OneRec 两种生成式推荐模型上均取得了最优的推荐性能, 超越了 RQ-KMeans、RQ-VAE 和 LETTER 等基线方法。消融实验表明, 图像模态和 CF 信号对语义 ID 质量均有显著贡献, 且二者之间存在互补效应, 同时去除两者导致 NDCG@10 下降 5.6%。语义 ID 质量分析表明, COMET 的碰撞率仅为 1.45%, 远低于 RQ-KMeans 的 8.48%、RQ-VAE 的 2.45% 和 LETTER 的 2.26%, 有效缓解了因语义 ID 碰撞导致的推荐精度损失。

第 5 章 总结与展望

5.1 工作总结

本文围绕生成式推荐中语义 ID 的构建问题，提出了 COMET (Collaborative-guided Multimodal Encoding Tokenizer) 方法。主要工作和贡献总结如下：

(1) 针对现有语义 ID 构建方法模态利用单一、协同过滤信号融合间接的问题，提出了 CF-as-Query 跨注意力融合机制。该机制以协同过滤嵌入为查询，以文本多 token 投影和图像嵌入构成的键值序列为键值对，通过堆叠的跨注意力和前馈网络自适应地从内容特征中提取推荐相关信息。与 LETTER 的辅助损失方式相比，COMET 将协同过滤信号从损失层面的间接引导提升为架构层面的直接融合，无需引入额外的对比损失函数。

(2) 提出了多目标重建策略，通过三个独立的解码器分支以加权方式同时重建文本、图像和协同过滤嵌入，促进多模态信息在 64 维隐空间中的均衡编码。配合余弦退火学习率调度和训练时 Sinkhorn 均匀化等训练策略，进一步提升了语义 ID 的质量。

(3) 搭建了从数据处理、多模态嵌入提取、语义 ID 构建到生成式推荐的完整实验流水线，实现了 RQ-KMeans、RQ-VAE、LETTER 和 COMET 四种语义 ID 构建方法在 TIGER 和 OneRec 两种生成式推荐模型上的公平对比。实验结果表明，COMET 在所有设置下均取得了最优的推荐性能。

5.2 未来展望

尽管 COMET 取得了较好的实验结果，仍有以下方向值得进一步探索：

(1) **更多模态的融入**。当前 COMET 融合了文本、图像和协同过滤三种模态。在实际应用中，物品还可能具有其他模态信息（如视频、评论文本情感、价格区间等），跨注意力架构天然支持扩展更多的 Key-Value token，未来可以探索更丰富的模态融合。

(2) **端到端联合训练**。当前 COMET 的语义 ID 构建和下游生成模型是分阶段训练的。将两者端到端联合优化可能进一步提升性能，使语义 ID 的构建直接面向推荐目标进行优化。

(3) **更大规模数据集验证**。当前实验仅在 Amazon Beauty 数据集上进行。未来应在更多领域和更大规模的数据集上验证 COMET 的泛化能力。

参考文献

- [1] HIDASI B, KARATZOGLOU A, BALTRUNAS L, et al. Session-based recommendations with recurrent neural networks[C]//Proceedings of the 4th International Conference on Learning Representations (ICLR). 2016.
- [2] KANG W C, MCAULEY J. Self-attentive sequential recommendation[C]//Proceedings of the IEEE International Conference on Data Mining (ICDM). 2018: 197-206.
- [3] RAJPUT S, MEHTA N, SINGH A, et al. Recommender systems with generative retrieval[C]//Advances in Neural Information Processing Systems (NeurIPS). 2023.
- [4] ZHENG B, HOU Y, LU H, et al. Adapting large language models by integrating collaborative semantics for recommendation[C]//Proceedings of the IEEE International Conference on Data Engineering (ICDE). 2024.
- [5] LEE D, KIM C, KIM S, et al. Autoregressive image generation using residual quantization [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 11523-11532.
- [6] RENDLE S, FREUDENTHALER C, SCHMIDT-THIEME L. Factorizing personalized Markov chains for next-basket recommendation[C]//Proceedings of the International Conference on World Wide Web (WWW). 2010: 811-820.
- [7] TANG J, WANG K. Personalized top-N sequential recommendation via convolutional sequence embedding[C]//Proceedings of the ACM International Conference on Web Search and Data Mining (WSDM). 2018: 565-573.
- [8] SUN F, LIU J, WU J, et al. BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformers[C]//Proceedings of the ACM International Conference on Information and Knowledge Management (CIKM). 2019: 1441-1450.
- [9] TAY Y, TRAN V, DEGHANI M, et al. Transformer memory as a differentiable search index [C]//Advances in Neural Information Processing Systems (NeurIPS). 2022.
- [10] RAFFEL C, SHAZEER N, ROBERTS A, et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research, 2020, 21(140): 1-67.
- [11] GENG S, LIU S, FU Z, et al. Recommendation as language processing (RLP): A unified pre-train, personalized prompt & predict paradigm (P5)[C]//Proceedings of the ACM Conference on Recommender Systems (RecSys). 2022: 299-315.
- [12] ZHANG Z, SUN Z, XIN X, et al. OneRec: Unifying retrieve and rank with generative recommender and iterative preference alignment[A]. 2025.
- [13] ZHANG B, SENNRICH R. Root mean square layer normalization[C]//Advances in Neural Information Processing Systems (NeurIPS). 2019.
- [14] SHAZEER N. GLU variants improve transformer[A]. 2020.

- [15] HE R, MCAULEY J. VBPR: Visual Bayesian personalized ranking from implicit feedback[C]//Proceedings of the AAAI Conference on Artificial Intelligence (AAAI). 2016: 144-150.
- [16] WEI Y, WANG X, NIE L, et al. MMGCN: Multi-modal graph convolution network for personalized recommendation of micro-video[C]//Proceedings of the ACM International Conference on Multimedia (MM). 2019: 1437-1445.
- [17] ZHOU H, ZHOU X, ZENG Z, et al. A comprehensive survey on multimodal recommender systems: Taxonomy, evaluation, and future directions[A]. 2023.
- [18] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//Proceedings of the International Conference on Machine Learning (ICML). 2021: 8748-8763.
- [19] WANG B, ZHANG J, WU B, et al. Qwen3-embedding: Advancing text embedding and reranking through foundation models[A]. 2025.
- [20] CUTURI M. Sinkhorn distances: Lightspeed computation of optimal transport[C]//Advances in Neural Information Processing Systems (NeurIPS). 2013: 2292-2300.
- [21] MCAULEY J, TARGETT C, SHI Q, et al. Image-based recommendations on styles and substitutes[C]//Proceedings of the International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR). 2015: 43-52.
- [22] WANG Y, CHEN L, ZHAO J, et al. LC-Rec: Semantics-guided generative retrieval for sequential recommendation[C]//Proceedings of the European Conference on Information Retrieval (ECIR). 2024.

致 谢

致谢内容待填写。

声 明

本人郑重声明：所呈交的综合论文训练论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：_____ 日 期：_____